

***Named Entity Recognition Untuk Data Review Tempat Wisata
Dengan Metode “Bidirectional Encoder Representations from
Transformers”***



Disusun Oleh:

N a m a : Muhammad Irfan

NIM : 17523149

PROGRAM STUDI INFORMATIKA – PROGRAM SARJANA

FAKULTAS TEKNOLOGI INDUSTRI


UNIVERSITAS ISLAM INDONESIA

2022

HALAMAN PENGESAHAN DOSEN PEMBIMBING

***Named Entity Recognition Untuk Data Review Tempat Wisata
Dengan Metode “Bidirectional Encoder Representations from
Transformers”***

TUGAS AKHIR




(Dhomas Hatta Fudholi, S.T., M.Eng., Ph.D.)

HALAMAN PENGESAHAN DOSEN PENGUJI

***Named Entity Recognition Untuk Data Review Tempat Wisata
Dengan Metode “Bidirectional Encoder Representations from
Transformers”***

TUGAS AKHIR

Telah dipertahankan di depan sidang penguji sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer dari Program Studi Informatika di Fakultas Teknologi Industri Universitas Islam Indonesia
Yogyakarta, 14 Januari 2022

Tim Penguji

Dhomas Hatta Fudholi, S.T., M.Eng.,
Ph.D.**Anggota 1**

Sheila Nurul Huda, S.Kom., M.Cs.

Anggota 2

Septia Rani, S.T., M.Cs.

Mengetahui,

Ketua Program Studi Informatika – Program Sarjana
Fakultas Teknologi Industri
Universitas Islam Indonesia



(Dr. Raden Teduh Dirgahayu, S.T., M.Sc.)

HALAMAN PERNYATAAN KEASLIAN TUGAS AKHIR

Yang bertanda tangan di bawah ini:

Nama : Muhammad Irfan

NIM : 17523149


Tugas akhir dengan judul:

***Named Entity Recognition Untuk Data Review Tempat Wisata
Dengan Metode “Bidirectional Encoder Representations from
Transformers”***

Menyatakan bahwa seluruh komponen dan isi dalam tugas akhir ini adalah hasil karya saya sendiri. Apabila di kemudian hari terbukti ada beberapa bagian dari karya ini adalah bukan hasil karya sendiri, tugas akhir yang diajukan sebagai hasil karya sendiri ini siap ditarik kembali dan siap menanggung risiko dan konsekuensi apapun.

Demikian surat pernyataan ini dibuat, semoga dapat dipergunakan sebagaimana mestinya.

Yogyakarta, 27 Desember 2021



(Muhammad Irfan)

HALAMAN PERSEMBAHAN

Tugas Akhir ini saya persembahkan untuk kedua orangtua saya yang saya sayangi dan saya cintai, yang telah mendidik dan mengasuh saya hingga saat ini, serta kepada keluarga, saudara teman-teman dan seluruh pihak yang telah memberikan semangat, bantuan, dukungan doa serta motivasi kepada saya selama proses pengerjaan dari awal hingga akhir, juga kepada diri saya sendiri yang telah menjalani, melalui dan menyelesaikan segala prosesnya sehingga dapat menyelesaikannya dengan lancar.



HALAMAN MOTO

“There is reward for kindness to every living thing”

– **Nabi Muhammad SAW**

“Karena sesungguhnya sesudah kesulitan itu ada kemudahan. Sesungguhnya sesudah kesulitan itu ada kemudahan”

– **Q.S. Al-Insyirah Ayat 5-6**



KATA PENGANTAR

Assalamualaikum Warahmatullahi Wabarakatuh.

Alhamdulillahirabbil ‘alamin, penulis memanjatkan puji syukur kepada Allah S.W.T. yang telah memberikan rahmat, hidayah, nikmat serta karunia-Nya sehingga penulis dapat menyelesaikan Tugas Akhir yang berjudul “*Named Entity Recognition Untuk Data Review Tempat Wisata Dengan Metode Bidirectional Encoder Representations from Transformers*” guna memenuhi syarat untuk menyelesaikan pendidikan pada jenjang sarjana. Dalam proses penyelesaiannya, tentu tidak lepas dari beberapa kendala yang dihadapi, namun, atas do’a, bimbingan, dukungan, semangat serta motivasi dari segala pihak dan diri sendiri, satu per satu kendala tersebut berhasil dilalui. Oleh karena itu, penulis ingin menyampaikan apresiasi dan rasa terima kasih kepada:


1. Kedua orangtua penulis yang selalu ada, selalu mendukung, mendo’akan dan memberi semangat kepada penulis, semoga mereka diberikan rezeki yang melimpah dan kesehatan serta lindungan oleh Allah SWT.
2. Seluruh keluarga penulis yang selalu memberikan motivasi serta dukungan.
3. Bapak Prof. Fathul Wahid, S.T., M.Sc., Ph.D. selaku Rektor Universitas Islam Indonesia.
4. Bapak Dr. Raden Teduh Dirgahayu, S.T., M.Sc. selaku Kaprodi Informatika – Program Sarjana UII.
5. Bapak Dhomas Hatta Fudholi, S.T., M.Eng., Ph.D. selaku dosen pembimbing yang sudah bersedia meluangkan waktu dan tenaga dalam memberikan ilmu serta bimbingan kepada penulis dalam menyelesaikan tugas akhir dengan baik.
6. Seluruh dosen Informatika UII yang telah memberikan ilmunya yang sangat bermanfaat, semoga bapak dan ibu selalu diberi kesehatan dan lindungan dari Allah SWT.
7. Teman-teman Halghib dan Andany Danty yang senantiasa selalu menemani serta memberikan semangat positif, motivasi dan dukungan dalam proses menjalankan penelitian.
8. Serta tidak kalah pentingnya, saya ingin berterima kasih kepada diri saya sendiri karena sudah percaya kemampuan diri saya sendiri, bekerja keras, tidak pernah menyerah serta melawan kemalasan saya sendiri dalam melakukan tugas akhir ini.

Penulis menyadari bahwa tugas akhir ini jauh dari kata sempurna dan masih memiliki kekurangan, namun penulis berharap dengan disusunnya laporan tugas akhir ini bisa bermanfaat untuk semua orang serta dapat dikembangkan menjadi hal yang lebih baik lagi ke depannya yang dapat berguna bagi semua orang.

Yogyakarta, 27 Desember 2021

"

(Muhammad Irfan)



SARI

Negara Indonesia merupakan negara yang menjadi salah satu tujuan wisata, biasanya wisatawan ketika akan mengunjungi tempat wisata akan mencari informasi terlebih dahulu. Informasi tersebut sangat lah penting untuk calon wisatawan, tetapi dengan adanya banyak sekali *review* tempat wisata akan memperlambat informasi yang ingin diketahui oleh calon wisatawan, sehingga tidak dapat langsung menemukan informasi yang diinginkan.

Named Entity Recognition (NER) dapat digunakan untuk membantu menemukan informasi penting yang dibutuhkan dengan mendeteksi entitas yang terdapat dalam suatu teks. Tujuan dari penelitian ini adalah membangun model NER yang berguna untuk membantu mengidentifikasi informasi pada *review* tempat wisata, dan mengetahui parameter terbaik yang digunakan dalam membangun model, serta mengetahui performa model yang dibangun. Dalam penelitian ini, terdapat 7723 *review* tempat wisata dari beberapa tempat wisata yang berada di Indonesia. Kumpulan *review* tersebut dipecah menjadi 207.993 token kata. Kemudian kata-kata yang telah dipecah akan diberi label entitas sesuai dengan kategori, beberapa kategori yaitu nama tempat wisata, nama lokasi, fasilitas, dan suasana. Selain dari kategori tersebut akan diberi label O yang berarti *outside*.

Dalam proses membangun model NER ada beberapa langkah untuk mencapai tujuan penelitian ini, yaitu mengumpulkan *dataset*, ekstraksi fitur dengan *word embedding* yaitu *WordPiece*, pemodelan NER, evaluasi dan deteksi entitas. Dalam penelitian ini menggunakan metode *Bidirectional Encoder Representations from Transformer* (BERT). BERT dipilih karena metode BERT ini dirancang untuk melatih representasi dua arah dari teks yang tidak berlabel dengan bersama-sama mengkondisikan konteks dari kiri dan kanan di semua lapisan. BERT mencapai hasil seni dalam banyak tugas seperti menjawab pertanyaan, interferensi bahasa dan *named entity recognition*. Dari hasil metode BERT ini diperoleh, model yang telah dibangun mampu mendeteksi entitas dengan cukup baik, namun ada beberapa kesalahan dalam mendeteksi entitas. Dari scenario yang dibuat dalam penelitian ini, diperoleh model dengan rata-rata F1-Score sebesar 75%.

Kata kunci: Named Entity Recognition, BERT, Wisata

GLOSARIUM

<i>Dataset</i>	himpunan data yang digunakan ketika membangun fitur dan model.
<i>False Negative</i>	hasil ketika model salah dalam memprediksi kelas negatif.
<i>False Positive</i>	hasil ketika model salah dalam memprediksi kelas positif.
<i>Hyperparameter</i>	variabel yang mempengaruhi keluaran model.
<i>List</i>	tipe data pada <i>python</i> yang mampu menyimpan lebih dari satu daftar nilai.
<i>Neural Network</i>	jaringan dari sekelompok unit pemroses kecil yang dimodelkan berdasarkan sistem saraf manusia.
<i>Node</i>	titik-titik yang menghubungkan satu satu jaringan ke jaringan lainnya
<i>Parameter</i>	variabel konfigurasi yang bersifat internal pada model.
<i>True Positive</i>	hasil ketika model dengan benar memprediksi kelas positif.
<i>Tuple</i>	tipe data pada <i>python</i> yang digunakan untuk menyimpan sekumpulan data yang isinya tidak dapat berubah.
<i>Hidden Layer</i>	Lapisan tersembunyi.
<i>Dropout</i>	Teknik regulasi untuk mengurangi <i>overfitting</i>
<i>Overfitting</i>	Overfitting terjadi ketika model menjadi sangat baik dalam mengklasifikasikan atau memprediksi data

DAFTAR ISI

HALAMAN JUDUL	i
HALAMAN PENGESAHAN DOSEN PEMBIMBING	ii
HALAMAN PENGESAHAN DOSEN PENGUJI	iii
HALAMAN PERNYATAAN KEASLIAN TUGAS AKHIR.....	iv
HALAMAN PERSEMBAHAN	v
HALAMAN MOTO	vi
KATA PENGANTAR.....	vii
SARI	ix
GLOSARIUM	x
DAFTAR ISI	xi
DAFTAR TABEL	xiii
DAFTAR GAMBAR.....	xiv
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Batasan Masalah	3
1.4 Tujuan Penelitian	3
1.5 Manfaat Penelitian	3
1.6 Sistematika Penulisan	4
BAB II LANDASAN TEORI	5
2.1 Penelitian Terkait	5
2.2 Dasar Teori.....	8
2.2.1 Natural Language Processing (NLP).....	8
2.2.2 <i>Machine Learning</i>	8
2.2.3 <i>Neural Network</i>	9
2.2.4 <i>Deep Learning</i>	9
2.2.5 Transformer	10
2.2.6 Named Entity Recognition	13
2.2.7 Bidirectional Encoder Representations from Transformers (BERT)	14
2.2.8 Ekstraksi Fitur	17
2.2.9 WordPiece	18
2.2.10 Pre-Training BERT	18

2.2.11	Fine-Tuning BERT	21
BAB III METODOLOGI PENELITIAN		22
3.1	Tahap-tahap Pengerjaan Tugas Akhir	22
3.2	Uraian Metodologi	22
3.2.1	Pengambilan <i>Dataset</i>	22
3.2.2	Preprocessing	23
3.2.3	Pelabelan Entitas	29
3.2.4	Ekstraksi Fitur	31
3.2.5	Pemodelan Named Entity Recognition	32
3.2.6	Evaluasi Model	34
3.2.7	Deteksi Entitas	35
BAB IV HASIL DAN PEMBAHASAN		36
4.1	Dataset	36
4.2	<i>Preprocessing</i>	36
4.3	Pelabelan Entitas	40
4.4	Mempersiapkan Data Masukan	42
4.5	Ekstraksi Fitur	42
4.6	Pemodelan Named Entity Recognition	43
4.7	Evaluasi Model	46
4.8	Deteksi Entitas	49
BAB V KESIMPULAN DAN SARAN		51
5.1	Kesimpulan	51
5.2	Saran	52
DAFTAR PUSTAKA		53
LAMPIRAN		56

DAFTAR TABEL

Tabel 3.1 Contoh menghilangkan kata yang tidak memiliki arti penting.....	23
Tabel 3.2 Contoh menghapus simbol.....	24
Tabel 3.3 Contoh menghapus kode NON ASCII.....	24
Tabel 3.4 Contoh menghapus nomor / digit.....	25
Tabel 3.5 Contoh menghapus URL	26
Tabel 3.6 Contoh menghapus karakter <i>mention</i> dan <i>hashtag</i>	26
Tabel 3.7 Contoh menormalkan kata yang tidak lengkap atau typo.....	27
Tabel 3.8 Contoh menggabungkan proses preprocessing.....	28
Tabel 3.9 Contoh tokenisasi.....	29
Tabel 3.10 Jenis macam label dan keterangan.....	30
Tabel 3.11 Hasil ekstraksi fitur	32
Tabel 3.12 Rangkuman scenario model BERT.....	34
Tabel 4.1 Jumlah token pada setiap label	41
Tabel 4.2 Hasil evaluasi skenario 1 model BERT	47
Tabel 4.3 Hasil evaluasi skenario 2 model BERT	48
Tabel 4.4 Hasil evaluasi skenario 3 model BERT	48

DAFTAR GAMBAR

Gambar 2.1 Menunjukkan hubungan antara Artificial Intelligence, Machine Learning, Deep Learning	10
Gambar 2.2 Encoder (kiri) dan Decoder (kanan).....	12
Gambar 2.3 Penerapan <i>Named Entity Recognition</i>	14
Gambar 2.4 Arsitektur BERT	15
Gambar 2.5 Perbedaan antara BERT BASE dan BERT LARGE.	15
Gambar 2.6 perbedaan antara arsitektur BERT dengan OpenAI GPT, ELMo.....	16
Gambar 2.7 BERT Single Sentence.....	17
Gambar 2.8 WordPiece Embedding	18
Gambar 2.9 Proses Masked Language Modelling	20
Gambar 2.10 proses Pre-Training BERT	20
Gambar 3.1 Langkah pengerjaan tugas akhir	22
Gambar 3.2 <i>Dataset</i> NER	23
Gambar 3.3 Teknik dropout.....	33
Gambar 4.1 Kode program untuk menghapus karakter yang tidak memiliki arti penting	36
Gambar 4.2 Kode program untuk menghapus karakter berlebih	37
Gambar 4.3 Kode program menghapus karakter NON-ASCII.....	37
Gambar 4.4 Kode program menghapus digit.....	37
Gambar 4.5 Kode program untuk menghapus URL.....	37
Gambar 4.6 Kode program untuk menghapus karakter <i>mention</i> dan <i>hashtag</i>	38
Gambar 4.7 Kode program untuk mernormalkan kata yang tidak lengkap.....	38
Gambar 4.8 Kode program menggabungkan semua kode <i>preprocessing</i>	39
Gambar 4.9 Kode program proses tokenisasi	39
Gambar 4.10 Hasil tokenisasi	40
Gambar 4.11 Menunjukkan kata yang sudah diberi label.....	41
Gambar 4.12 Kode program persiapan data ke model BERT	42
Gambar 4.13 Ekstraksi fitur dengan teknik <i>WordPiece embedding</i>	43
Gambar 4.14 Kode program data splitting.....	44
Gambar 4.15 Kode program membangun model BERT	44
Gambar 4.16 Kode program proses <i>fine-tuning</i>	45
Gambar 4.17 Kode Program Melatih BERT.....	46
Gambar 4.18 Kode Program Evaluasi BERT	47

Gambar 4.19 Hasil proses deteksi entitas menggunakan model BERT.....	49
--	----



BAB I PENDAHULUAN

1.1 Latar Belakang

Negara Indonesia merupakan salah satu negara tujuan wisata. Indonesia memiliki berbagai macam wisata antara lain wisata alam, wisata alam terdiri dari berbagai macam wisata yaitu wisata pantai, wisata bukit, wisata candi, wisata gunung dan terdapat wisata yang mengunjungi museum-museum yang berada di Indonesia. Adanya berbagai macam tempat wisata yang berada di Indonesia akan menarik perhatian para wisatawan sehingga dapat mengunjungi daerah wisata tersebut. Pada dasarnya pariwisata dapat diandalkan untuk meningkatkan kesejahteraan masyarakat dan pembangunan nasional.

Pariwisata di Indonesia merupakan sektor ekonomi yang paling penting di Indonesia, karena di Indonesia banyak destinasi-destinasi wisata yang cukup bagus. Pemerintah juga sudah mengakui potensi pariwisata yang berada di Indonesia. Pariwisata yang telah berkembang dapat ditandai dengan perkembangan jumlah pengunjung maupun turis dan pendapatnya berasal dari turis tersebut. Menurut United World Tourism Organization (UNWTO), sektor pariwisata berperan penting dalam menyumbang 9% dari total GDP dunia (Sabon, Perdana, Koropit, & Pierre, 2018).

Tripadvisor adalah situs wisata terbesar di dunia yang membantu wisatawan dalam merencanakan dan memesan perjalanan wisata, selain itu Tripadvisor juga dapat memberikan rekomendasi seperti hotel, resort, penginapan, paket liburan, penyewaan tempat berlibur. Situs web Tripadvisor merupakan komunitas wisata terbesar di dunia yang menjangkau 350 juta pengunjung setiap bulannya, serta menampilkan lebih dari 320 juta ulasan dan opini 6,2 juta akomodasi, restoran dan objek wisata (Cambria, Valdivia, Luzón, & Herrera, 2017). Pada awalnya Tripadvisor merupakan sebuah situs *Business to Business* yang bertujuan untuk mempertemukan produsen dengan produsen bukan produsen dengan konsumen, seiring berjalannya waktu situs ini dimanfaatkan oleh para komunitas traveller untuk berbagi pengalaman mereka, dari situlah Tripadvisor berubah menjadi review site untuk pariwisata. Berdasarkan laman website TripAdvisor, dijelaskan bahwa 83% pengguna global TripAdvisor biasanya melakukan *review* ulasan-ulasan yang berada di laman *website* TripAdvisor sebelum melakukan perjalanan. Selain itu juga, 8 dari 10 pengguna menyetujui bahwa TripAdvisor memilih untuk mempertimbangkan serta membaca *review* terlebih dahulu sebelum melakukan perjalanan wisata. Sebanyak 73% pengguna TripAdvisor telah menulis

review karena wisatawan ingin membagikan pengalaman yang baik dengan wisatawan lain. Tetapi dengan banyaknya ulasan yang ada dari banyaknya review dapat membuat wisatawan kesulitan dalam menemukan informasi.

Berdasarkan masalah tersebut diperlukan pendekatan NER, *Named Entity Recognition* adalah sebuah ekstraksi informasi dan pemrosesan dokumen secara terstruktur dan tidak terstruktur yang mengacu nama orang, tempat, organisasi dan waktu (Mansouri, Affendey, & Mamat, 2008). Dengan mengetahui entitas tersebut, maka akan dapat diperoleh diperoleh penting tentang ulasan wisata seperti nama tempat wisata, nama lokasi, fasilitas dan sebagainya. Namun demikian, melakukan ekstraksi entitas tersebut ada beberapa permasalahan yang dihadapi seperti adanya penulisan entitas yang beragam dan tidak konsisten. Oleh karena itu, penerapan model NER diharapkan dapat mempermudah mendapatkan informasi yang dibutuhkan wisatawan.

Penelitian ini mengenai Named Entity Recognition pada *review* tempat wisata. Dengan penelitian ini dapat memberikan kemudahan wisatawan terutama dalam mencari tempat wisata yang terdapat pada review atau ulasan wisata, sehingga membantu wisatawan memperoleh informasi penting dalam memilih destinasi wisata. Entitas yang diidentifikasi pada penelitian ini merupakan nama wisata, nama tempat, fasilitas dan suasana. Entitas yang biasanya muncul dalam domain wisata yaitu nama wisata, nama tempat, fasilitas. Penelitian ini melakukan penambahan entitas baru yaitu entitas suasana. Berikut ini penjelasan beberapa entitas, Entitas nama wisata merupakan entitas yang mengidentifikasi tentang destinasi wisata, sedangkan entitas nama tempat merupakan entitas yang mengidentifikasi nama lokasi wisata, sedangkan entitas fasilitas merupakan entitas yang mengidentifikasi fasilitas yang berada di destinasi wisata seperti tempat parkir, mushola, toilet dan entitas suasana merupakan entitas yang mengidentifikasi suasana yang berada di destinasi wisata seperti dingin, panas, ramai, sepi, nyaman. Penelitian ini akan menggunakan metode *Bidirectional Encoder Representations from Transformers* (BERT).

Penelitian NER menggunakan metode BERT pernah dilakukan (Chantrapornchai & Tunsakul, 2019). Metode BERT merupakan metode terkini yang dapat digunakan untuk membangun model Named Entity Recognition dan memiliki hasil yang baik, sebagai contoh pada penelitian (Chantrapornchai & Tunsakul, 2019).

1.2 Rumusan Masalah

Berdasarkan latar belakang diatas, maka dapat dirumuskan suatu rumusan masalah seperti:

1. Bagaimana mengidentifikasi hyperparameter terbaik dalam membangun model NER dalam *review* tempat wisata dengan BERT ?
2. Bagaimana mengidentifikasi entitas sebagai informasi penting dalam *review* tempat wisata dengan BERT ?

1.3 Batasan Masalah

Batasan yang terdapat pada penelitian ini seperti :

1. Menggunakan data yang berbahasa indonesia
2. Data yang digunakan data yang diambil dari *website TripAdvisor* dengan memilih tempat wisata yang terdapat di Indonesia
3. Entitas yang akan diidentifikasi hanya nama wisata, nama tempat, fasilitas dan suasana.

1.4 Tujuan Penelitian

Tujuan dari penelitian ini seperti:

1. Membangun model *Named Entity Recognition* yang dapat membantu mengidentifikasi entitas penting yang terdapat pada *review* wisata dengan menggunakan metode BERT.
2. Mempermudah wisatawan mendapatkan informasi penting pada *review* wisata.

1.5 Manfaat Penelitian

Manfaat dari penelitian ini seperti:

1. Mengetahui performa model NER yang dibangun dengan menggunakan metode BERT.
2. Mempermudah dalam mengidentifikasi nama wisata, nama tempat, fasilitas dan suasana.

1.6 Sistematika Penulisan

Sistematika penulisan dalam laporan tugas akhir sebagai berikut:

BAB I : Pendahuluan

Bab pendahuluan merupakan bab yang berisi tentang latar belakang dan gambaran umum penelitian tentang “*Named Entity Recognition Untuk Data Review Tempat Wisata menggunakan metode Bidirectional Encoder Representations from Transformers (BERT)*”, rumusan masalah, tujuan penelitian, batasan penelitian, manfaat penelitian dan sistematika penulisan.

BAB II : Landasan Teori

Bab landasan teori merupakan bab yang berisi tentang penjelasan mengenai penelitian yang telah dilakukan sebelumnya dan dasar teori yang membahas tentang *Natural Language Preprocessing, Named Entity Recognition, Machine Learning, Neural Network, Deep Learning, Transformer, Bidirectional Encoder Representations from Transformer*.

BAB III : Metodologi Penelitian

Bagian ini memberikan penjelasan langkah-langkah yang dilakukan dalam penelitian ini.

BAB IV : Hasil dan Pembahasan

Bab Hasil dan pembahasan ini menjabarkan hasil serta evaluasi dari penelitian mengenai *Named Entity Recognition Untuk Data Review Tempat Wisata*.

BAB V : Kesimpulan dan Saran

Bab kesimpulan dan saran ini menjelaskan hasil yang diperoleh dari penelitian ini dan memberikan saran agar dapat membantu dalam melakukan penelitian selanjutnya.

BAB II

LANDASAN TEORI

2.1 Penelitian Terkait

Bagian ini akan menjelaskan tentang penelitian yang dilakukan pada penelitian sebelumnya dan dijadikan sebagai referensi dalam membuat penelitian ini. Penelitian-penelitian tersebut ditunjukkan pada Tabel 2.1.

Tabel 2.1 Penelitian-penelitian terkait

No	Judul Penelitian	Metode	Hasil
1	Development of Semi-Supervised Named Entity Recognition to Discover New Tourism Places (Saputro, Kusumawardani, & Fauziati, 2017)	Yet Another Two Stage Idea (YATSI) dikombinasi Naive Bayes Classifier(NBC) dan K-Nearest Neighbor(KNN)	Penelitian yang menerapkan machine learning dengan menggunakan NER berbasis semi-supervised dan unsupervised. Metode yang digunakan metode Yet Another Two Stage Idea yaitu algoritma SSL yang memiliki dua tahap proses. Pada tahap pertama, YATSI ini dilatih menggunakan data berlabel, sehingga Naive Bayes dipilih dalam penelitian ini karena probabilistik dan mudah untuk diimplementasikan. Pada tahap kedua, algoritma ini mencoba untuk memprediksi data tidak berlabel dengan pendekatan K-Nearest Neighbor. Dalam penelitian ini entitas yang diterapkan Nature, City, Region, Negative. Hasil performa akurasi mendapatkan 70,43% dan F-Measure 69,1%.
2	Information Extraction based on Named Entity for Tourism Corpus (Chantrapornchai & Tunsakul, 2019)	BERT	Penelitian yang menerapkan NER dengan menggunakan metode BERT yang mengekstraksi entitas seperti <i>Location</i> (LOC), <i>Organization</i> (ORG) dan <i>Facility</i> (FAC) dari data review TripAdvisor, Traveloka dan Hotels.com. Model dibangun dengan BERT, entitas LOC/ORG mendapatkan akurasi 0,258, untuk entitas FAC mendapatkan akurasi 0,245 dan untuk LOC/ORG/FAC mendapatkan akurasi 0,464.

3	A Deep Learning Approach for Chinese Tourism Field Attribute Extraction (Hu, Nuo, & Tang, 2019)	BERT, ResCNNs, BLSTM, CRF	Penelitian ini menerapkan metode BERT yang dikombinasikan dengan ReCNNs-BLSTM-CRF. Penerapan mekanisme model untuk yang pertama, melakukan pelabelan urutan. Kedua, melakukan penyematan karakter sebagai masukan. Entitas yang diterapkan dalam penelitian ini yaitu location, organization, dan person untuk <i>dataset</i> MSRA dan untuk <i>dataset</i> CTFAE entitas yang diterapkan yaitu include area, construction time, location, nickname, internal attraction. Hasil performa dari beberapa metode yang dikombinasikan berhasil mendapatkan hasil F1-Score yang cukup tinggi yaitu 95,41% untuk <i>dataset</i> MSRA dan untuk <i>dataset</i> CTFAE mendapatkan 92,17%.
4	A Method of Chinese Tourism Named Entity Recognition Based on BBLC Model (Xue, Cao, Ye, & Qin, 2019)	BERT, BLSTM, CRF	Penelitian ini menerapkan metode BERT dan dikombinasikan dengan BLSTM dan CRF yang bisa disebut BBLC Model. Mekanisme Model BBLC untuk NER, BERT bertujuan menghasilkan model bahasa dan encoder transformer untuk membaca seluruh urutan teks, BLSTM memproses seluruh urutan teks, dan CRF menghasilkan pelabelan data dengan format BIO tag. Penelitian menerapkan entitas person, location, organization, time, thing. Hasil F1-Score dari BBLC model mendapat 84,79%.
5	Knowledge Extraction Experiment Based on Tourism Knowledge Graph Q A Data Set (Liang, Cao, & Zhang, 2020)	BERT, BLSTM, CRF	Penelitian ini menerapkan metode dalam NER yaitu BERT-BLSTM-CRF. Mekanisme yang diterapkan dalam penelitian ini yaitu BERT yang digunakan untuk mendapatkan vector kata, BLSTM yang digunakan untuk pemberian kode teks input dari dua arah dan CRF digunakan untuk mengeluarkan urutan label dengan kategori setiap karakter. Hasil

			performa yang dihasilkan dalam penelitian ini untuk <i>dataset</i> Shaanxi Tourist mendapatkan akurasi 89,77% dan untuk <i>dataset</i> Nlpcc Universal mendapatkan akurasi 96,93%.
6	Information Extraction on Tourism Domain using Spacy and BERT (Chantrapornchai & Tunsakul, 2021)	BERT, SpaCy	Penelitian ini menerapkan metode BERT dan library SpaCy. Penerapan metode BERT, karena menggunakan format BIO Tag yang dapat mengidentifikasi nama organisasi, nama tempat, dan fasilitas dan penerapan Library SpaCy, karena telah dibuat model untuk mengidentifikasi nama organisasi, nama tempat, dan fasilitas. Mekanisme Library SpaCy untuk NER merupakan pemrosesan fitur seperti tokenisasi, <i>part of speech</i> . Modelnya stokastik dan proses pelatihan dilakukan menggunakan gradien. Mekanisme dari BERT untuk NER tag untuk entitas bernama yang harus dilabeli dan juga harus melatih model untuk mengenalinya, sehingga dapat mengekstrak relasi yang diinginkan. Entitas yang diterapkan dalam penelitian yaitu location, facility, organization. Hasil performa mendapatkan akurasi 95% - 98%.

Penelitian ini mengangkat topik yaitu *named entity recognition* (NER) didalam domain wisata menggunakan metode BERT. Peneliti menggunakan NER pada review tempat wisata untuk membantu wisatawan dalam memperoleh informasi penting yang terdapat didalamnya. Penelitian ini menggunakan metode BERT dipilih karena metode BERT merupakan dalam mengidentifikasi entitas bernama seperti entitas nama wisata, nama tempat wisata, fasilitas dan suasana. Penelitian ini juga diharapkan dapat membantu dalam memperbanyak entitas terhadap model NER, karena dalam penelitian ini juga menambahkan entitas baru yaitu suasana. BERT memiliki keunggulan dalam kemampuan untuk melatih model bahasa berdasarkan seluruh kata dalam kalimat. Ekstraksi fitur dalam penelitian ini menggunakan *word embedding* dengan teknik BERT. BERT memiliki word embedding khusus untuk metode BERT sendiri yaitu *WordPiece embedding*, *WordPiece embedding* mempunyai kegunaan untuk mengambil

kalimat input dan akan menyimpan setiap kata sebagai satu kata utuh. Ketika tokenizer tersebut digunakan ada beberapa kata yang berimbuhan simbol ## pada kata tersebut.

2.2 Dasar Teori

2.2.1 Natural Language Processing (NLP)

Natural language processing atau biasa disebut dengan pengolahan bahasa alami yang merupakan salah satu cabang ilmu *Artificial Intelligence* (AI) yang berfokus dalam mengolah bahasa natural. Bahasa natural merupakan bahasa yang digunakan manusia untuk berkomunikasi dengan komputer. Natural language preprocessing adalah teknik komputasi untuk menganalisis mempresentasikan teks alami pada satu atau lebih tingkat analisis linguistik dengan tujuan mencapai pemrosesan bahasa seperti manusia untuk berbagai tugas atau aplikasi (Fimoza, 2019). Tugas utama dari NLP adalah *Natural Language Understanding* (NLU) dan *Natural Language Generation* (NLG). NLP juga bertugas sebagai peringkasan otomatis, ekstraksi otomatis, *information retrieval* dan *named entity recognition* (NER). Menurut pengolahan bahasa alami memiliki beberapa komponen utama (Putra & Hidayatullah, 2021), yaitu:

- a. Parser, berfungsi untuk melakukan analisis sintaksis
- b. Sistem representasi pengetahuan, berfungsi untuk menganalisis keluaran *parser* untuk menentukan maknanya, dalam hal ini bermaksud sistem representasi pengetahuan adalah kamus yang berisi kata-kata bahasa alami.
- c. *Output Translator*, berfungsi dalam mempresentasikan sistem pengetahuan, yaitu hasil terjemahan memasukan bahasa alami

2.2.2 Machine Learning

Machine Learning merupakan salah satu cabang aplikasi pendekatan dalam AI atau menirukan manusia untuk menyelesaikan masalah atau otomatisasi. Machine learning menirukan bagaimana proses manusia belajar dan mengeneralisasi. Machine learning juga mempunyai dua cabang aplikasi utama yaitu klasifikasi dan prediksi. Ciri khas ML yang dapat dilihat yaitu adanya proses pelatihan, pembelajaran, atau training. Klasifikasi merupakan metode yang digunakan oleh mesin untuk memilah obyek dengan ketentuan tertentu sebagaimana manusia mencoba membedakan benda satu dengan yang lain. Sedangkan prediksi merupakan mesin yang digunakan untuk menangkap keluaran dari data masukan berdasarkan data yang sudah dipelajari dalam training (Ahmad Hania, 2017).

Secara umum, *machine learning* dibagi menjadi beberapa kategori besar yaitu *supervised learning*, *unsupervised learning*, *self-supervised learning*, dan *reinforcement learning* (Fimoza, 2019). *Supervised learning* merupakan pendekatan yang berguna membuat mesin mempelajari *dataset* yang telah diberi label. *Unsupervised learning* merupakan pendekatan dengan memberikan *dataset* yang tidak diberi label. *Self-supervised learning* merupakan seperti kategori *supervised learning* tetapi tanpa *dataset* yang tidak dilabeli. *Dataset* yang digunakan tetap menggunakan label yang telah didapatkan dari input data yang menggunakan algoritma *heuristic* (Fimoza, 2019). Metode pada *machine learning* populer atau sering digunakan merupakan Support Vector Machine (SVM) dan Neural Network (Ahmad Hania, 2017).

2.2.3 Neural Network


Neural Network atau jaringan syaraf tiruan adalah teknik yang terdapat pada *machine learning* dengan menirukan jaringan syaraf manusia, *Neural Network* terdiri dari lapisan masukan atau *input layer* dan lapisan keluaran atau *output layer* (Ahmad Hania, 2017). Setiap lapisan terdiri atas satu atau beberapa neuron yang akan menghasilkan sebuah fungsi aktivasi yang menentukan keluaran dari unit tersebut. Dalam melakukan sebuah fungsi aktivasi dapat menambahkan lapisan tersembunyi atau *hidden layer* untuk menambah kemampuan dari *Neural Network* tersebut (Fimoza, 2019). NN dapat dilatih dengan menggunakan data yang disebut data training. Dalam *Neural Network* semakin banyak data training maka akan menghasilkan hasil yang bagus dalam kerja *Neural Network*, tetapi NN juga memiliki kelemahan jika lapisan semakin banyak maka semakin tinggi kapasitas NN tersebut. Semakin banyak lapisan maka semakin banyak juga iterasi atau training yang dibutuhkan, untuk mengatasi hal ini, dikembangkan teknik *Deep Learning* (Ahmad Hania, 2017).

2.2.4 Deep Learning

Deep Learning merupakan cabang dari *machine learning* yang merupakan bagian dari Kecerdasan buatan. *Deep learning* merupakan *neural network* yang bersifat deep atau mendalam karena *deep learning* lebih banyak layer daripada *neural network*. Kata “deep” mengacu pada jumlah *hidden layer* yang ada, semakin banyak layer-nya, maka semakin “deep” pembelajaran yang dilakukan jaringan (Fimoza, 2019). *Deep learning* bekerja untuk mempelajari sehingga tidak hanya dapat memprediksi tetapi juga mempresentasikan data dengan benar, sehingga cocok untuk melakukan prediksi. *Deep learning* dapat dikategorikan

beberapa metode pendekatan yaitu *supervised*, *semi-supervised* dan *unsupervised*. *Deep learning* didukung oleh banyak *framework* seperti Torch, Theano, TensorFlow, dan lain-lain (Fimoza, 2019).

Deep learning bidang pembelajaran mesin yang terdiri dari beberapa lapisan pemrosesan untuk mempelajari representasi data dengan beberapa tingkat abstraksi. Keuntungan menggunakan *deep learning* adalah kemampuan representasi pembelajaran dan komposisi semantik yang diberdayakan oleh keduanya representasi vektor dan pemrosesan saraf. Teknik penerapan *deep learning* untuk NER ada beberapa hal. Pertama, NER mendapatkan manfaat dari non-linear transformasi, yang menghasilkan pemetaan non-linear dari masukan ke keluaran (Li, Sun, Han, & Li, 2020). Model berbasis *deep learning* dapat mempelajari fitur yang kompleks dari data melalui fungsi aktivasi non-linier. Kedua, *deep learning* menghemat upaya signifikan dalam merancang fitur NER, fitur dalam NER membutuhkan cukup banyak keahlian teknik dan keahlian domain (Li et al., 2020). Model berbasis *deep learning*, efektif dalam belajar secara representasi otomatis dan faktor yang berguna untuk mendasari dari data mentah.



Gambar 2.1 Menunjukkan hubungan antara Artificial Intelligence, Machine Learning, Deep Learning

Sumber: (Fimoza, 2019)

2.2.5 Transformer

Transformer merupakan arsitektur yang didasarkan untuk menarik perhatian dan menarik ketergantungan global antara input output dan menggantikan lapisan yang paling umum digunakan dalam arsitektur encoder dan decoder (Vaswani et al., 2017). Model transformer menunjukkan seni baru dalam kualitas terjemahan, sementara itu dapat dilatih secara signifikan

lebih cepat daripada arsitektur berdasarkan lapisan berulang atau *convolutional*. Transformer adalah dua pilar utama *Natural Language Processing* modern, salah satu model transformer *pre-trained* yang paling populer yaitu *Bidirectional Encoder Representations from Transformers* (BERT). Transformers dapat mengkonversi pemahaman yang diperoleh dengan mekanisme yang bernama *self-attention mechanism*. *Self-attention mechanism* merupakan cara transformer untuk mengubah atau mengkonversikan kata terkait sehingga kata-kata tersebut akan diproses melalui mekanisme Transformer (Fimoza, 2019). Terdapat dua mekanisme pada Transformer, yaitu:


1. Encoder

Encoder berguna untuk membaca keseluruhan teks input secara bersama. Encoder mempunyai *stack* (tumpukan) dari $N = 6$ *layers* yang identik. Setiap layer memiliki dua sub-layer yaitu *self-attention layer* dan *feed-forward neural network*. *Self-attention layer* dalam encoder berguna untuk membantu node agar tidak fokus dengan kata yang sedang dilihat tetapi juga untuk mendapatkan konteks semantik dari kata tersebut (Fimoza, 2019).

Setiap posisi di encoder dapat menangani semua posisi dilayer sebelumnya di encoder.

2. Decoder

Decoder berguna untuk menghasilkan urutan *output* yang berupa prediksi. Decoder juga mempunyai *stack* (tumpukan) sebanyak $N = 6$ *layers* yang identik. Setiap layer terdiri dari dua sub-layer seperti yang pada *encoder*, tetapi didalam *decoder* ada penambahan *attention layer* diantara dua layer tersebut. Dua layer tersebut ditambah dengan *attention layer* berguna untuk membantu node saat mendapatkan *key content* yang membutuhkan *attention* (Vaswani et al., 2017) dengan melakukan *multi-head attention* pada *output* dari *encoder*. *Self attention layer* di decoder membuat setiap posisi di *decoder* dapat menangani semua posisi sebelumnya dan posisi saat itu (Fimoza, 2019).



Gambar 2.2 Encoder (kiri) dan Decoder (kanan).

Sumber: (Vaswani et al., 2017)

Langkah langkah berikut menunjukkan proses yang terjadi pada *encoder* dan *decoder* (Fimoza, 2019)

1. Setiap input kata yang memasuki *encoder* diubah menjadi sebuah *list vector* menggunakan *embeddings* karena *self-attention layer* tidak membedakan urutan kata-kata pada sebuah kalimat. *Positional encoding* ditambahkan untuk menunjukkan posisi dari setiap kata. Setiap vektor dari kata input memiliki ukuran sebesar 512. Proses ini hanya berlaku di *encoder* yang berada paling bawah, sehingga encoder lainnya dapat menerima output dari *encoder* pertama (Vaswani et al., 2017).
2. Input vektor melewati dua layer yang ada setiap encoder yaitu *self-attention layer* dan *feed-forward neural network*. *Self-attention layer* dibuat tiga vektor yang terbagi dalam masing masing vektor input yaitu Query, Key, dan Value vector. Tiga vektor ini dibuat dengan mengalihkan *embedding*. Dimensi dari tiap vektor masing masing yaitu 64. *Self-attention layer* dari tiap kata dihitung dengan mengalihkan *query vector* dan *key vector* seperti pada Gambar 2.2 (Vaswani et al., 2017).

3. Setelah itu, nilai *self-attention* dibagi 8 karena nilai 8 adalah akar kuadrat dari dimensi tiap vektor memiliki nilai ukuran 64. Nilai *self-attention* juga dihitung dengan *softmax* sehingga setiap *value vector* akan dikali dengan nilai *softmax*. Hasilnya *value vector* dijumlahkan dan menjadi output dari *self-attention layer*. Output dari *self-attention layer* kemudian masuk ke *feed-forward* untuk setiap posisi seperti Gambar 2.2(Vaswani et al., 2017).

2.2.6 Named Entity Recognition

Named entity recognition merupakan proses ekstraksi informasi dan pemrosesan dokumen secara terstruktur yang mengacu nama orang, nama tempat, organisasi dan waktu. Sebuah entitas telah terdeteksi oleh NER yang berada di dokumen dan dari dokumen tersebut NER dapat menentukan entitas tersebut sesuai dengan kategorinya. *Named entity recognition* adalah tugas mendasar dan merupakan inti dari sistem *natural language processing* (NLP)(Mansouri et al., 2008). NER mempunyai dua tugas, tugas yang pertama mengidentifikasi nama diri dalam teks dan kedua, mengklasifikasi teks-teks dalam satu set kategori seperti dengan mengetahui entitas nama orang, nama lokasi, dan organisasi, maka akan dapat diperoleh informasi penting tentang ulasan wisata seperti nama tempat wisata, nama lokasi wisata, fasilitas dan sebagainya.

Penggunaan NER dapat diaplikasikan dalam kehidupan sehari-hari di berbagai kasus, seperti pemberian kode indeks pada buku, membuat mesin pencarian yang telah di program agar mendapatkan hasil yang lebih akurat, membuat program *preprocessing* untuk menyederhanakan tugas seperti mesin translasi. *Named entity tagger* merupakan bagian penting dalam proses ekstraksi informasi yang lebih kompleks (Mansouri et al., 2008). Sebagai tugas dalam mengenali entitas bernama serta mendeteksi jenisnya. Sebagai contoh, Candi Borobudur terletak di Magelang, Candi Borobudur dapat dideteksi dalam entitas wisata dan Magelang dapat dideteksi dalam entitas lokasi.

Tetapi penggunaan NER untuk manusia secara intuitif sederhana, karena banyak entitas bernama seperti nama orang, nama tempat yang menggunakan huruf kapital diawal kata sangat mudah dimengerti atau dikenali oleh manusia, tetapi untuk mesin dalam mengenali entitas bernama tersebut sangat sulit. Orang berfikir bahwa mesin dalam mengenali entitas bernama mudah dimengerti dengan menggunakan kamus, karena sebagian entitas bernama itu merupakan kata benda. Seiring berjalannya waktu, kata benda semakin lebih banyak dan tidak mungkin semua tercakup atau terdaftar dalam kamus. Permasalahan dalam *named entity*

recognition merupakan kata yang memiliki ambiguitas seperti kata benda (Mansouri et al., 2008).


contentSkip to site indexPoliticsSubscribeLog InSubscribeLog InToday's PaperAdvertisementSupported ORG byF.B.I. Agent Peter Strzok PERSON , Who Criticized Trump PERSON in Texts, Is FiredImagePeter Strzok, a top F.B.I. GPE counterintelligence agent who was taken off the special counsel investigation after his disparaging texts about President Trump PERSON were uncovered, was fired. CreditT.J. Kirkpatrick PERSON for The New York TimesBy Adam Goldman ORG and Michael S. SchmidtAug PERSON . 13 CARDINAL , 2018WASHINGTON CARDINAL — Peter Strzok PERSON , the F.B.I. GPE senior counterintelligence agent who disparaged President Trump PERSON in inflammatory text messages and helped oversee the Hillary Clinton PERSON email and Russia GPE investigations, has been fired for violating bureau policies, Mr. Strzok PERSON 's lawyer said Monday DATE .Mr. Trump and his allies seized on the texts — exchanged during the 2016 DATE campaign with a former F.B.I. GPE lawyer, Lisa Page — in PERSON assailing the Russia GPE investigation as an illegitimate "witch hunt." Mr. Strzok PERSON , who rose over 20 years DATE at the F.B.I. GPE to become one of its most experienced counterintelligence agents, was a key figure in the early months DATE of the inquiry.Along with writing the texts, Mr. Strzok PERSON was accused of sending a highly sensitive search warrant to his personal email account.The F.B.I. GPE had been under immense political pressure by Mr. Trump PERSON to dismiss Mr. Strzok PERSON , who was removed last summer DATE from the staff of the special counsel, Robert S. Mueller III PERSON . The president has repeatedly denounced Mr. Strzok PERSON in posts on

Gambar 2.3 Penerapan *Named Entity Recognition*.

Sumber : <https://djajafer.medium.com/>


2.2.7 Bidirectional Encoder Representations from Transformers (BERT)

Bidirectional Encoder Representations from Transformers (BERT) bagian dari *Transformer* tetapi hanya berbeda langkah sebelumnya, menutup beberapa token input secara acak dan menambahkan tujuan untuk memprediksi kata yang ditutup hanya berdasarkan konteks token di sekitarnya, karena arsitektur *Transformers* digunakan seluruh urutan token sekaligus konteks input dipelajari dari sisi kiri dan kanan secara bersama-sama (Devlin et al., 2019). BERT mencapai hasil seni dalam banyak tugas seperti menjawab pertanyaan, interferensi bahasa dan pengenalan entitas bernama (Taher, Hoseini, & Shamsfard, 2020). BERT yang telah dilatih sebelumnya dalam model yang berbeda pada teks mentah yang belum dilabeli. Model dua arah yang telah dilatih sebelumnya dengan satu lapisan keluaran dapat mencapai hasil mutakhir dalam banyak tugas seperti menjawab pertanyaan. Cara kerja BERT dengan memanfaatkan *Transformers* dan *Attention Mechanism* yang mempelajari hubungan kontekstual antara kata atau sub kata dalam sebuah teks. *Transformers* menyertakan dua mekanisme terpisah yaitu encoder yang membaca input teks dan decoder yang menghasilkan prediksi untuk tugas tersebut, karena tujuan menggunakan metode BERT untuk menghasilkan model bahasa hanya menggunakan mekanisme encoder yang diperlukan. BERT memiliki arsitektur umum yang sesuai dengan permasalahan dan model yang meminimalkan data yang sudah berlabel (Taher et al., 2020). Arsitektur BERT dapat dilihat pada Gambar 2.4




Gambar 2.4 Arsitektur BERT

Arsitektur model BERT merupakan pengkodean multi layer dari dua arah seperti yang dilakukan pada implementasi asli Transformer tetapi hanya menggunakan *encoder* saja. Pada implementasi yang diterapkan pada penelitian (Vaswani et al., 2017) terdapat dua ukuran model yang ada pada BERT, model pertama BERT BASE dan BERT LARGE. Kedua ukuran model BERT ini memiliki lapisan *encoder* dan Transformer Blocks. BERT BASE memiliki *encoder* dengan 12 *layers*, 12 *self-attentions heads*, *hidden size* sebesar 768, dan 110M *parameters*. Sedangkan BERT LARGE terdapat 24 *layers*, 16 *self-attentions heads*, *hidden size* sebesar 1024, dan 340M *parameters* (Devlin et al., 2019). Perbedaan antara BERT BASE dan BERT LARGE dapat dilihat pada Gambar 2.5.



Gambar 2.5 Perbedaan antara BERT BASE dan BERT LARGE.

Model BERT ini hanya menggunakan *encoder* saja, sehingga arsitektur BERT terlihat pada Gambar 2.4. BERT berbeda dengan model terarah (*directional*) ketika membaca teks dari kiri ke kanan, kanan ke kiri atau gabungan dari kiri ke kanan dan kanan ke kiri. Model bahasa yang dilatih secara *bidirectional* dapat memiliki pemahaman yang lebih dalam tentang konteks membaca teks dengan model bahasa satu arah (Fimoza, 2019). Pada Gambar 2.6 menunjukkan perbandingan antara arsitektur BERT, OpenAIGPT dan ELMo. Perbandingan antara ketiga arsitektur tersebut, Arsitektur BERT yang secara bersamaan melihat kepada konteks kiri dan kanan disetiap layernya.



Gambar 2.6 perbedaan antara arsitektur BERT dengan OpenAI GPT, ELMo

Sumber: (Devlin et al., 2019)

Ada dua langkah yang terlibat dalam BERT: pre-training dan fine tuning. Saat pre-training model BERT memahami dan mempelajari pada data tidak berlabel dengan dua tugas unsupervised yaitu Masked Language Model (MLM) dan Next Sentence Prediction (NSP).

a. Masked Language Model (MLM)


Tugas MLM adalah memberi mask atau menutupi 15% kata-kata ke setiap urutan token input secara acak dan kemudian memprediksi nilai asli dari token yang ditutupi.

b. Next Sentence Prediction (NSP)

Dalam proses pre-training, BERT dapat menerima pasangan kalimat sebagai input dan dilatih untuk memprediksi jika pasangan kalimat tersebut adalah kalimat berikutnya atau hanya satu kalimat saja. Jika ada kalimat A dan B, maka 50% BERT akan menganggap bahwa kalimat B adalah kalimat berikutnya dari kalimat A. Sedangkan 50% lainnya adalah kalimat acak yang diambil dari corpus.

Untuk melatih sebuah model bahasa, classifier perlu dilatih dengan sedikit perubahan pada model BERT selama fase pelatihan (training) yang disebut finetuning. Menurut (Devlin et al., 2019) terdapat rekomendasi hyperparameters yang dapat di-fine-tuning untuk mencapai hasil yang maksimal. Fine-tuning sangat mudah dilakukan karena mekanisme self-attention di

Transformer membuat BERT bisa membuat model untuk berbagai tugas, baik pada kalimat tunggal (single sentence) atau kalimat berpasangan, dengan menukar masukan dan keluaran yang sesuai. BERT digunakan untuk menangani berbagai tugas hilir, masukan representasi dapat menjelaskan satu kalimat atau sepasang kalimat. Pada Gambar 2.7 BERT dengan *single sentence*.



Gambar 2.7 BERT Single Sentence


Sumber: (Devlin et al., 2019)

2.2.8 Ekstraksi Fitur

Ekstraksi fitur merupakan salah proses yang berguna untuk melakukan proses pelatihan, karena dalam pembelajaran mesin yang digunakan hanya dapat melakukan proses pelatihan menerima masukan berupa angka (Giarsyani, 2020). Ekstraksi fitur ini berguna untuk memperoleh informasi dari sampel asli sehingga mempresentasikan sebagai vektor yang dinormalisasikan dengan ukuran yang sama. Ekstraksi fitur mempunyai tujuan membantu meningkatkan kinerja sistem dan memberikan prediksi (Wang, Huang, & Gao, 2020). Ekstraksi fitur dapat membantu menentukan entitas yang akan dikategorikan. Jenis fitur ada bermacam-macam. Namun yang digunakan dalam penelitian ini menggunakan *Word Embedding* dengan teknik *WordPiece Tokenizer*. *Word embedding* dipilih karena pada penelitian (Gravano, 2010) terbukti mampu membantu model mendapatkan hasil yang lebih baik dibanding fitur lainnya. *Word embedding* banyak membantu algoritma pembelajaran NLP, menunjukkan bahwa sebuah kata dalam kalimat dipetakan oleh vektor nyata dalam sebuah dimensi yang rendah.

2.2.9 WordPiece

WordPiece Tokenizer merupakan algoritma segmentasi subword yang awalnya digunakan untuk *Neural Machine Translation* dan algoritmanya kemudian digunakan dalam model BERT(Quijano, Nguyen, & Ordonez, 2021). Tujuan penerapan *Wordpiece Tokenizer* dalam model BERT, karena Wordpiece mempunyai manfaat untuk lebih mudah mengidentifikasi kata-kata dan Wordpiece biasanya akan berbagi token input yang sama kemudian masuk ke lapisan BERT. Cara kerja *Wordpiece* ada 2 langkah, untuk langkah yang pertama pra token teks merupakan proses untuk memisahkan tanda baca dan spasi. Langkah yang kedua menandai setiap potongan kata menjadi potongan kata. Ada beberapa aturan dasar *wordpiece* seperti memberikan spasi disekitar tanda baca, untuk setiap kata yang dihasilkan, jika kata tersebut ditemukan didalam *vocabulary wordpiece* akan ada kata yang dipertahankan dan ada kata yang akan dipisah dengan menggunakan “##” pada bagian kata yang tersisa. BERT menggunakan *WordPiece Tokenizer* dengan banyak 30.000 kosa kata token. Token pertama menggunakan token klasifikasi khusus ([CLS]), setiap kata yang di token dengan *WordPiece* akan mendapatkan tambahan awalan ([CLS]). Pasangan kalimat dikemas bersama menjadi satu urutan, kalimat dibedakan dengan token khusus ([SEP]) pada akhir kalimat.



Gambar 2.8 WordPiece Embedding

Sumber: (Devlin et al., 2019)

Representasi masukan BERT ada pada Gambar 2.8. Penyematan input adalah jumlah penyematan token, penyematan segmentasi, dan penyematan posisi.

2.2.10 Pre-Training BERT


Pre-training merupakan proses bagian dari metode BERT yang dibuat untuk memahami dan mempelajari bahasa serta konteksnya. BERT dapat memahami proses training dengan dua proses *unsupervised* yang dilakukan bersamaan yaitu *Masked Language Model* dan *Next Sentence Prediction* (Devlin et al., 2019).

1. Masked Language Modelling (Masked LM)

Masked Language Modelling secara intuitif yaitu model dua arah yang benar-benar dalam sehingga lebih kuat daripada model kiri-ke-kanan atau gabungan dangkal dari kiri-ke-kanan dan dari model kanan-ke-kiri. Untuk melatih representasi dua arah yang dalam, dengan cukup menutupi beberapa presentasi input token secara acak dan memprediksi beberapa token yang bertopeng (Devlin et al., 2019). Sebelum input urutan kata kedalam BERT, 15% dari kata urutan diganti dengan token [MASK]. Setelah itu model mencoba memprediksi nilai asli dari kata yang telah diberi [MASK] dengan konteks yang telah diberikan oleh kata lain yang tidak ditutup oleh [MASK] di dalam urutan kata (Fimoza, 2019). Proses untuk mendapatkan model Pre-Training dua arah memiliki kelemahan yaitu menciptakan ketidaksesuaian antara Pre-Training dan Fine Tuning, karena token [MASK] tidak muncul selama Fine Tuning. Untuk mengurangi kelemahan ini, dengan melakukannya tidak selalu mengganti kata-kata “bertopeng” dengan token [MASK] yang sebenarnya. Secara teknis, prediksi kata-kata *output*:

- i) Membutuhkan lapisan klasifikasi diatas *output encoder*
- ii) Mengalihkan vector output dengan matriks *embedding* kemudian mengubah menjadi *vocabulary dimension*
- iii) Menghitung probabilitas dari setiap kata di *vocabulary* dengan *softmax*

Proses tersebut dapat dilihat pada Gambar 2.9.




Gambar 2.9 Proses Masked Language Modelling

Sumber: (Fimoza, 2019)

2. Next Sentence Prediction

Dalam proses training BERT, model dapat menerima pasangan kalimat sebagai input dan data latih untuk memprediksi jika kalimat kedua pasangan tersebut adalah kalimat berikutnya pada dokumen aslinya hanya satu kalimat saja. Gambar 2.10 menunjukkan proses Pre-Training BERT.



Gambar 2.10 proses Pre-Training BERT

Sumber: (Fimoza, 2019)

Untuk melatih sebuah model bahasa, classifier perlu dilatih dengan sedikit perubahan pada model BERT selama fase pelatihan atau *training* yang bisa disebut *fine tuning*. Menurut (Devlin et al., 2019) terdapat rekomendasi hyperparameters yang dapat di *fine tuning* untuk mencapai hasil yang maksimal. Fine tuning sangat mudah dilakukan karena mekanisme *self-attention* di Transformer, membuat BERT dapat membuat model untuk berbagai tugas, baik kalimat tunggal atau *single sentence* atau kalimat berpasangan dengan menukar masukan dan keluaran yang sesuai.

Sebagai representasi input BERT, terdapat 3 *embedding layer* yaitu:

- 1) *Token embeddings* adalah layer pertama yang dimasuki oleh token merupakan representasi vektor dari tiap token. Setiap token dalam input akan dipetakan ke representasi vector berdimensi tinggi dari token yang diberikan. Setelah di token akan diubah menjadi id yang didapat berdasarkan *vocabulary*.
- 2) *Sentence embeddings* menunjukkan kalimat pertama dan kedua ditambahkan ke setiap token dan digunakan untuk membedakan antar kalimat jika terdapat lebih dari dua kalimat. Lapisan representasi kata hanya ada dua yaitu A untuk kalimat yang termasuk kalimat pertama dan B untuk kalimat yang termasuk kalimat kedua.
- 3) *Positional embedding* ditambahkan setiap token untuk menyimpan informasi tentang posisi kata dalam urutan. Implementasi dari positional embedding

ditunjukkan pada Transformer. BERT telah mempelajari posisi *embedding layer* selama *pre-training*.

2.2.11 Fine-Tuning BERT


Fine tuning merupakan proses training model dengan *task* yang spesifik menggunakan model yang telah dilatih dengan *dataset* yang besar. Fine Tuning sangat mudah dilakukan karena mekanisme *self-attention* di Transformer memungkinkan BERT untuk memodelkan banyak tugas hilir, baik yang melibatkan teks tunggal atau pasangan teks (Devlin et al., 2019). Fine tuning sangat dibutuhkan untuk Pre-trained language model seperti BERT, model BERT jika dilatih dengan data yang besar dapat menghasilkan model yang mampu memahami model yang dipilih. Apabila tidak menggunakan Pre-trained language model akan memakan waktu dan *resource* yang lebih lama dan jika menggunakan Pre-trained language model, tugas akan semakin mudah karena sudah ada data besar yang dilatih dan tinggal di fine tuning. Fine tuning dapat digunakan dalam model BERT yang dapat diaplikasikan untuk *Named Entity Recognition* (NER).

BAB III

METODOLOGI PENELITIAN

3.1 Tahap-tahap Pengerjaan Tugas Akhir

Langkah-langkah pengerjaan tugas akhir dalam penelitian ini ditunjukkan pada Gambar 3.1. Langkah-langkah tersebut terdiri dari pengambilan dataset, preprocessing, pelabelan entitas, ekstraksi fitur, pemodelan NER, evaluasi model, memprediksi entitas.



Gambar 3.1 Langkah pengerjaan tugas akhir

3.2 Uraian Metodologi

3.2.1 Pengambilan Dataset

Data yang digunakan dalam penelitian *Named Entity Recognition* (NER) ini merupakan data yang diambil dari penelitian sebelumnya yang sudah ada, data penelitian tersebut milik (Abida, 2019). Data yang digunakan dalam penelitian (Abida, 2019) merupakan data ulasan ulasan tentang wisata yang diambil dari *website* TripAdvisor. Data tersebut merupakan data yang diambil secara acak tentang ulasan pariwisata yang berada di Indonesia dan data yang dikumpulkan hanya data yang berbahasa Indonesia. Data yang didapat dari penelitian sebelumnya merupakan data yang berbentuk file .csv. Data tersebut merupakan data yang akan digunakan untuk data latih terhadap pemodelan dan data uji yang digunakan untuk mengukur kinerja model NER yang telah dirancang. Gambar 3.2 merupakan *Dataset* yang digunakan dalam penelitian ini.

247 Kalo ke candi borobudur lebih baik datang pagi...udaranya masih segar ga terlalu cape naik tangga sampai paling atas..pesannya jangan pk celana pendek (

248 Kalau ke Kota Gudeg belum lengkap jika tidak berkunjung ke Candi Borobudur. Meskipun harus naik tangga yang banyak ditambah siang hari terik matahari

249 Paling cocok datang di pagi hari, tempat yang menarik dengan Candi Candi yang menakjubkan. Taman taman yang terawat dengan kebersihan yang di

250 merupakan 7 keajaiban dunia n wajib d kunjungi jika kalian berada d jogjakarta. banyak souvenir unik yg d perjualbelikan d kawasan candi ini. jika kalian mv

251 saya kesini awalnya sih merasa tempatnya jauh lhaa wong saya dari wonogiri, pas sampai sana ehh tempatnya bener bagus banget sambil belajar sejarah t

252 waktu berlibur bersama teman2 untuk melepas penat terasa sangat menyenangkan dengan perjalanan ke jogja.. kami ikut paket travel selama 4hr.. setelah

253 Datanglah jam 4 pagi. Menikmati keheningan pagi dipadu dengan indahnya proses matahari terbit, membuat anda merasakan pengalaman yang luar biasa

254 Dulu pernah kategori 7 keajaiban dunia, skrg kenapa tidak bisa mempertahankan?sejarah mengakuinya+unesco juga, kenapa? Atau kurang di rawat, batu_

255 ini adalah pengalaman pertama saya ke candi ini, saya banyak mendengar tentang kemegahan candi ini, itulah salah satu alasan saya jauh jauh dari Bali ke

256 Jadi kita ada kaya gank ataw temen kumpul kita...Kita liburan ke Yogya bareng nah salah satu nya ke candi Borobudur... Disini jujur agak panas tempat nya

257 Candi Borobudur ini merupakan candi terbesar di Indonesia, tempat wisata yang paling ramai dikunjungi. datanglah pagi atau sore, karena kalau siang terl

258 selain panas juga di sini menikmati candi harus berjalan kaki, apa lagi candi menanjak ke atas, mungkin cukup lelah, bayangkan saja kita membawa orang tu

259 bangunan yg luas besar dan tinggi perlu tenaga yg tidak sedikit untuk keatas puncak hehe. tapi semua akan terbayar benar2 aset negara yang harus dijaga.

260 Puluhan tahun berlalu sejak terakhir saya mengunjungi Candi Borobudur ini kelas 2 SMA, dan kali ini bersama keluarga besar.Tempat pertama setelah park

261 Kalau ke Yogyakarta ga lengkap kayaknya kalau tidak pergi ke candi Borobudur, makanya saya pun pergi kesana. Melihat candi bersejarah nya Indonesia. Te

262 Candi warisan dunia di magelang, datang kesana waktu tahun baruan , ramai banget agak susah dapat parkir . Pengaturan tiket sudah bagus, lalu lintas jala

263 Waktu yang tepat untuk mengunjungi borobudur adalah sore hari, karena saat siang hari panasnya sangat menyiksa, tetapi tenang saja banyak yang meny

264 Sebagai kelanjutan dari kunjungan ke Candi Prambanan, rasanya tidak lengkap kalau tidak mengunjungi Candi Brobudur. Dengan mengendarai mobil prib

265 Kalo ke borobudur enaknya pas hari kerja, jadi tidak terlalu ramai. Tempatnya relatif bersih, tapi panas. Harga tiket 30k, utk perorangan. Siapkan stamina u

266 Walaupun saya tidak ambil paket sunrise tour, namun Borobudur sudah buka pukul 6 pagi sehingga momen sunrise masih bisa dinikmati.Menikmati indah

267 September 2016,Borobudur Sunrise is a moment you shouldn't missed!Berangkat dari Jogja jam 03.30, dari Jogjakarta dengan mobil dan tiba sekitar 4.30 ki

268 Candi Borobudur adalah candi terbesar di dunia, kebanggaan Indonesia. Saya sarankan ke sini pagi pagi sekali. Bawa payung / pakai topi, pakai baju sopan

Gambar 3.2 Dataset NER

3.2.2 Preprocessing

Proses *preprocessing* harus dilakukan sebelum membuat model NER, *Preprocessing* merupakan suatu proses yang dilakukan untuk menyiapkan data agar dapat di proses. *Preprocessing* bermanfaat agar data masukan yang akan diproses akan lebih mudah untuk dikenali oleh komputer. Proses *preprocessing* dalam penelitian ini yang dilakukan yaitu menghilangkan kata yang tidak memiliki arti penting, menghapus simbol, menghapus kode non ascii, menghapus nomor atau digit, menghapus URL, menghapus karakter dari twitter, menormalkan kata yang tidak lengkap atau typo.

- a. Menghilangkan kata yang tidak memiliki arti penting.

Dalam tahap ini berguna untuk menghilangkan kata yang tidak memiliki arti penting.

Tabel 3.1 Contoh menghilangkan kata yang tidak memiliki arti penting

Sebelum	Sesudah
Main kesini karena ini salah satu warisan budaya indonesia,candi ini salah satu yg terbesar di indonesia,,sy tinggal di yogya juga tapi jarak nya kalo kesini lumayan jauh sihh,,tapi sayang 2 masa orang diy gapernah ke candi nya ,,Pengalaman berharga bisa kesini dengan teman2 alumni	Main kesini salah warisan budaya Indonesia, candi salah satu terbesar di indonesia tinggal yogya jarak kesini lumayan sih sayang diy gapernah candi pengalaman berharga kesini teman alumni

b. Menghapus simbol

Dalam tahap ini berguna untuk menghilangkan simbol. Simbol dihapus karena tidak memiliki pengaruh penting dalam penelitian yang akan dilakukan. Contoh menghapus simbol ditunjukkan pada Tabel 3.2.

Tabel 3.2 Contoh menghapus simbol

Sebelum	Sesudah
Hujan gak mengurangi hasrat kita untuk liburan Borobudur masi tetap menakjubkan seperti biasa ♡Saran saya sih berangkat pagi yaaa.. Soalnya siang ke sore biasanya udah ujan, kalo saya pribadi sih lebih suka musim ujan yaaa.. Gak perlu bawa apa2 ke sana.. Semua ada kok.. Payung, jas ujan, topi dll. Yg penting jgn lupa bawa duit yessss	Hujan gak mengurangi hasrat kita untuk liburan Borobudur masi tetap menakjubkan seperti biasa Saran saya sih berangkat pagi yaaa.. Soalnya siang ke sore biasanya udah ujan, kalo saya pribadi sih lebih suka musim ujan yaaa.. Gak perlu bawa apa2 ke sana.. Semua ada kok.. Payung, jas ujan, topi dll. Yg penting jgn lupa bawa duit yessss

c. Menghapus kode NON ASCII

Dalam tahap ini berguna untuk menghilangkan kode NON ASCII yang terdapat di dalam data ulasan wisata. Kode-kode NON ASCII merupakan kode yang tidak termasuk dalam kode ASCII. Contoh menghapus kode NON ASCII pada Tabel 3.3

Tabel 3.3 Contoh menghapus kode NON ASCII

Sebelum	Sesudah
Sangat indah keajaiban duina yang satu ini. benar-benar exotic..Harga tiket 30k/org untuk dewasa dan 12.5k/org untuk anak2 dibawah 6 tahun kami mengunjungi candi borobudur dengan keluar (suami dan anak 3,5 tahun)..Awalnya anak semangat jalan kaki ketika menuju puncak candi.. Tetapi ketika turun dari candi dia mulai kelelahan dan minta gendong.. Apalagi jarak candi ke pintu keluar (parkiran) sangat jauh, harus melewati pasar yang menjual pernik-	Sangat indah keajaiban duina yang satu ini. benar-benar exotic..Harga tiket 30k org untuk dewasa dan 12.5k org untuk anak2 dibawah 6 tahun kami mengunjungi candi borobudur dengan keluar suami dan anak 3,5 tahun..Awalnya anak semangat jalan kaki ketika menuju puncak candi.. Tetapi ketika turun dari candi dia mulai kelelahan dan minta gendong.. Apalagi jarak candi ke pintu keluar parkiran sangat jauh, harus melewati pasar yang menjual pernik-

pernik oleh-oleh..Kalau bisa untuk pihak pengelola Candi Borobudur, untuk pintu keluar jangan terlalu jauh, sangat kasihan untuk orang yang membawa anak / lansia harus berjalan jauh.	pernik oleh-oleh..Kalau bisa untuk pihak pengelola Candi Borobudur, untuk pintu keluar jangan terlalu jauh, sangat kasihan untuk orang yang membawa anak lansia harus berjalan jauh.
--	--

d. Menghapus nomor / digit

Dalam tahap ini digunakan untuk menghapus nomor atau digit yang berada pada data ulasan wisata. Menghapus nomor tersebut dilakukan karena entitas yang akan dilakukan di penelitian ini tidak ada yang berhubungan dengan nomor atau digit sehingga lebih baik untuk dihapus. Contoh menghapus nomor / digit pada Tabel 3.4.

Tabel 3.4 Contoh menghapus nomor / digit

Sebelum	Sesudah
Sangat indah keajaiban duina yang satu ini. benar-benar exotic..Harga tiket 30k/org untuk dewasa dan 12.5k/org untuk anak2 dibawah 6 tahun kami mengunjungi candi borobudur dengan keluar (suami dan anak 3,5 tahun)..Awalnya anak semangat jalan kaki ketika menuju puncak candi.. Tetapi ketika turun dari candi dia mulai kelelahan dan minta gendong.. Apalagi jarak candi ke pintu keluar (parkiran) sangat jauh, harus melewati pasar yang menjual pernak-pernik oleh-oleh..Kalau bisa untuk pihak pengelola Candi Borobudur, untuk pintu keluar jangan terlalu jauh, sangat kasihan untuk orang yang membawa anak / lansia harus berjalan jauh.	Sangat indah keajaiban duina yang satu ini. benar-benar exotic..Harga tiket k/org untuk dewasa dan k/org untuk anak dibawah tahun kami mengunjungi candi borobudur dengan keluar (suami dan anak tahun)..Awalnya anak semangat jalan kaki ketika menuju puncak candi.. Tetapi ketika turun dari candi dia mulai kelelahan dan minta gendong.. Apalagi jarak candi ke pintu keluar (parkiran) sangat jauh, harus melewati pasar yang menjual pernak-pernik oleh-oleh..Kalau bisa untuk pihak pengelola Candi Borobudur, untuk pintu keluar jangan terlalu jauh, sangat kasihan untuk orang yang membawa anak / lansia harus berjalan jauh.

e. Menghapus URL

Tahap ini berguna untuk menghapus URL karena tidak memiliki arti penting dalam penelitian yang akan dilakukan. Contoh menghapus URL ditunjukkan pada Tabel 3.5.

Tabel 3.5 Contoh menghapus URL

Sebelum	Sesudah
Museum ini hanya tutup pada hari senin. Untuk masuk ke museum anda hanya perlu membayar 30.000rupiah saja sudah termasuk guide di dalam museum. Selain restorannya anda juga dapat mengunjungi butik yang berada di bawah resto, elegan unik tapi anda juga harus bersiap merogoh kocek yang agak dalam :D. Coba datang museum bersama pasangan :) oh iya ada jam buka tutupnya, sebaiknya konfirmasi terlebih dahulu web addnya www.ullensentalu.com emailnya info@ullensentalu.com tel (62-274) 880158,895161 fax (62-274) 881743"Rasa dalam hati pupuklah agar sempurna hidupmu".	Museum ini hanya tutup pada hari senin. Untuk masuk ke museum anda hanya perlu membayar 30.000rupiah saja sudah termasuk guide di dalam museum. Selain restorannya anda juga dapat mengunjungi butik yang berada di bawah resto, elegan unik tapi anda juga harus bersiap merogoh kocek yang agak dalam :D. Coba datang museum bersama pasangan :) oh iya ada jam buka tutupnya, sebaiknya konfirmasi terlebih dahulu web addnya tel (62-274) 880158,895161 fax (62-274) 881743"Rasa dalam hati pupuklah agar sempurna hidupmu".

f. Menghapus karakter *mention* dan *hashtag*

Tahap ini akan melakukan proses menghapus karakter dari twitter seperti @, #. Karakter dari twitter dihapus karena tidak ada pengaruh penting dalam penelitian yang dilakukan. Contoh menghapus karakter dari twitter ditunjukkan pada Tabel 3.6.

Tabel 3.6 Contoh menghapus karakter *mention* dan *hashtag*

Sebelum	Sesudah
Masa dtg ke sni akan ada 3@4 point kalau xsilap. Stiap point yg kita akan sggah	Masa dtg ke sni akan ada 34 point kalau xsilap. Stiap point yg kita akan sggah

memberikan pemandangan dan cerita yg berbeza2. Kita jga blh tahu tntang sejarah di sana. Trdapat byk korban nyawa mahupun harta benda. Apa yg plg mnyedihkan bila nmpak sendiri secara langsung gmba2 dan brg2 yg musnah. Dtg lah kesini kalau dah smpai Jogja, pasti seronok. Naik Jeep tau, abg2 driver @ tour and guide pun best2. Sporting. Tlg mbikkan gambar lagi. Masa saya ngan kawan dtg sni, Mas Parjo yg guide kitaorang. Sgt2 baik, peramah dan sporting. Terima Kasih #teamEnjoyYourHoliday sbb sntiasa mmberikan yg terbaik utk kami. The best TOUR AND GUIDE EVER	memberikan pemandangan dan cerita yg berbeza2. Kita jga blh tahu tntang sejarah di sana. Trdapat byk korban nyawa mahupun harta benda. Apa yg plg mnyedihkan bila nmpak sendiri secara langsung gmba2 dan brg2 yg musnah. Dtg lah kesini kalau dah smpai Jogja, pasti seronok. Naik Jeep tau, abg2 driver tour and guide pun best2. Sporting. Tlg mbikkan gambar lagi. Masa saya ngan kawan dtg sni, Mas Parjo yg guide kitaorang. Sgt2 baik, peramah dan sporting. Terima Kasih teamEnjoyYourHoliday sbb sntiasa mmberikan yg terbaik utk kami. The best TOUR AND GUIDE EVER
---	--

g. Menormalkan kata yang tidak lengkap atau typo

Dalam tahap ini sangat penting dibutuhkan karena dalam melakukan pengenalan entitas dalam penelitian seperti ini akan membantu lebih mudah untuk mengenal kata-kata tersebut. Dalam contoh pada Tabel 3.7 seperti kata Asyik diubah menjadi Asik dan kata atu diubah menjadi atau. Tahap ini akan dilakukan karena untuk menormalkan kata yang tidak lengkap maupun typo sehingga dapat mengandung makna yang sesuai.

Tabel 3.7 Contoh menormalkan kata yang tidak lengkap atau typo

Sebelum	Sesudah
Untuk Candi yang merupakan candi terbesar tetap saja kalau dipenuhi pengunjung bisa crowded banget. Asyik buat di jelajahi pas sore hari biar gak panas. Sayang banyak sekali stupa atu relief yang hilang dicuri orang.	Untuk Candi yang merupakan candi terbesar tetap saja kalau dipenuhi pengunjung bisa crowded banget. Asik buat di jelajahi pas sore hari biar gak panas. Sayang banyak sekali stupa atau relief yang hilang dicuri orang.

h. Menggabungkan proses *preprocessing*

Dalam tahap ini berguna untuk menggabungkan semua program preprocessing agar menjadi satu kode program dengan berbagai fungsi. Tahap ini hanya untuk mempermudah pengecekan proses *preprocessing*. Contoh pada Tabel 3.8 dalam menggabungkan proses *preprocessing*.

Tabel 3.8 Contoh menggabungkan proses preprocessing

Sebelum	Sesudah
Kami memilih menaiki kereta kuda dan ini merupakan pilihan yang tepat karena menikmati angin sepoi-sepoi sambil naik kereta kuda, Kusirnya pun sangat responsif. Beliau menyarankan tempat-tempat yang bagus untuk mengambil foto dengan latar belakang Candi Borobudur dan beliau yang mengambil fotonya. Jadi kami 2-3 kali berhenti dan mengambil foto sebelum akhirnya sampai di Candi. Untuk menaikin Candi, disarankan memakai sepatu yang nyaman karena tangganya cukup curam dan padat.	Kami memilih kereta kuda pilihan menikmati angin sepoi-sepoi kereta kuda, Kusirnya responsif. Beliau menyarankan tempat-tempat bagus mengambil foto latar Candi Borobudur mengambil fotonya. Jadi berhenti mengambil foto Candi. Untuk menaikin Candi, disarankan memakai sepatu nyaman tangganya curam padat.

i. Tokenisasi

Tokenisasi merupakan proses pemecahan teks menjadi kata-kata yang lebih kecil. Beberapa teks yang telah dipecah menjadi beberapa kata yang lebih kecil bisa disebut token. Dalam proses tokenisasi sangat dibutuhkan karena dalam pengenalan entitas teks harus di tokenisasi agar mudah dalam mengenali entitas setiap kata. Contoh tokenisasi pada Tabel 3.9.

Tabel 3.9 Contoh tokenisasi

Sebelum	Sesudah
Keluarga saya sangat menikmati wisata Jogja terutama Malioboro, keluarga mengunjungi malioboro pada waktu malam hari, cuaca dingin dan suasana sangat ramai.	['Keluarga', 'saya', 'sangat', 'menikmati', 'wisata', 'Jogja', 'terutama', 'Malioboro', ',', 'keluarga', 'mengunjungi', 'malioboro', 'pada', 'waktu', 'malam', 'hari', ',', 'cuaca', 'dingin', 'dan', 'suasana', 'sangat', 'ramai', '.']

3.2.3 Pelabelan Entitas

Dalam tahap setelah melakukan *preprocessing*, tahap selanjutnya adalah melakukan pelabelan entitas pada data ulasan wisata. Dalam tahap ini data tersebut akan diberikan label entitas yang telah melalui proses tokenisasi pada *preprocessing* sesuai dengan kategori entitasnya. Pelabelan entitas data yang digunakan untuk penelitian ini masih secara manual. Pelabelan entitas dalam data yang akan digunakan ada beberapa macam yaitu entitas nama wisata, nama lokasi, fasilitas dan suasana. Entitas nama wisata diterapkan pada penelitian ini karena, dataset yang diambil untuk penelitian merupakan data dari *review* atau ulasan-ulasan dari TripAdvisor dan dalam *review* tersebut banyak yang memberikan ulasan dengan mencantumkan nama wisata tersebut, sehingga perlu dideteksi dengan NER agar lebih mudah mengenali nama wisata ketika membaca banyak ulasan. Berikut ini penjelasan dari beberapa macam entitas yang akan digunakan dalam penelitian ini:

a. Nama Wisata

Entitas ini merupakan entitas yang berisi tentang nama-nama wisata yang berada di Indonesia, seperti Candi Borobudur, Candi Prambanan, Malioboro, Pantai Kuta, Pantai Parangtritis, Gunung Merapi dan lain-lain. Nama-nama wisata yang berada dalam data akan diberikan label Nama Wisata.

b. Nama Lokasi

Entitas ini merupakan entitas yang berisi tentang nama lokasi tempat wisata yang berada di Indonesia, seperti Yogya, Magelang, Bali, Jakarta dan lain-lain. Nama-nama lokasi wisata yang berada dalam data akan diberi label nama lokasi.

c. Fasilitas

Entitas ini merupakan entitas yang berisi fasilitas yang berada di tempat wisata Indonesia, seperti mushola, kamar mandi, tempat parkir, souvenir, tempat berfoto, shuttle bus. Fasilitas dapat berupa pelayanan dari tempat wisata sehingga wisatawan dalam menikmati wisata dapat lebih nyaman.

d. Suasana

Entitas ini merupakan entitas yang berisi tentang bagaimana kondisi di tempat wisata tersebut, seperti tenang, ramai, panas, dingin, sejuk, dan lain-lain. Suasana dapat juga berupa cuaca dari tempat wisata.

Proses pelabelan entitas yang akan dilakukan yaitu data dilabeli dengan menggunakan format *Beginning Inside Outside* (BIO) karena entitas memiliki sejumlah token(hoesen purwarianti). Proses pelabelan dari format BIO dilakukan dengan cara memberikan entitas berdasarkan posisi atau arti katanya. Pelabelan entitas diurutkan dengan kata pertama yaitu diberi label “B” yang berarti *Begin*, apabila kata entitas lebih dari satu dan berurutan dengan kata pertama yaitu diberi label “I” yang berarti *Inside*. Selanjutnya apabila tidak termasuk dalam kata entitas yang berada di kategori maka akan diberi label “O” yang berarti *Outside*. Tabel berikut merupakan contoh pelabelan format BIO yang dilakukan di penelitian ini. Tabel 3.10 menunjukkan jenis macam label dan keterangan.

Tabel 3.10 Jenis macam label dan keterangan

Label	Keterangan	Contoh
B-WISATA	Kata pertama (Begin)pada entitas nama tempat wisata diberi label B-WISATA	Gunung Merapi
I-WISATA	Kata kedua setelah entitas kata pertama (Inside) akan diberi label I-WISATA	Gunung : B-WISATA Merapi : I-WISATA
B-LOKASI	Kata pertama (Begin)pada entitas nama lokasi wisata diberi label B-LOKASI	Pulau Bali

I-LOKASI	Kata kedua setelah entitas kata pertama (Inside) akan diberi label I-LOKASI	Pulau : B-LOKASI Bali : I-LOKASI
B-FASILITAS	Kata pertama (Begin)pada entitas nama lokasi wisata diberi label B-FASILITAS	Tempat Parkir
I-FASILITAS	Kata kedua setelah entitas kata pertama (Inside) akan diberi label I-FASILITAS	Tempat : B-FASILITAS Parkir : I-FASILITAS
B-SUASANA	Kata pertama (Begin)pada entitas nama lokasi wisata diberi label B-SUASANA	Panas Terik
I-SUASANA	Kata kedua setelah entitas kata pertama (Inside) akan diberi label I-SUASANA	Panas : B-SUASANA Terik : I-SUASANA
O	Kata-kata yang tidak termasuk dalam label entitas nama tempat wisata, nama lokasi, fasilitas dan suasana akan diberi label O (<i>Outside</i>)	Main kesini Main : O Kesini : O

3.2.4 Ekstraksi Fitur

Ekstraksi fitur yang digunakan dalam penelitian ini adalah *WordPiece*. *WordPiece* merupakan ekstraksi fitur yang populer dengan metode BERT. Fitur dari *WordPiece* berguna untuk mempresentasikan data yang berbentuk teks menjadi berbentuk vektor. BERT menggunakan *WordPiece Embeddings* dari 30.000 token kosa kata. Token pertama dari setiap urutan selalu merupakan token klasifikasi khusus ([CLS]) dan token terakhir dari setiap urutan selalu dibedakan dengan token khusus ([SEP]). Ekstraksi fitur dalam metode BERT terdapat 2 proses, untuk proses yang pertama merupakan proses tokenizer dengan *wordpiece* tokenizer dan untuk proses yang kedua merupakan proses *word embedding* dengan *word embedding* BERT. Data yang dipresentasikan ini akan menghasilkan angka dalam setiap kata dalam data tersebut. Setiap data yang sudah di ubah menjadi angka akan mempunyai makna, agar dapat

mempermudah dalam melakukan pemodelan *Named Entity Recognition*. Tabel 3.11 menunjukkan hasil ekstraksi fitur.

Tabel 3.11 Hasil ekstraksi fitur


Kata	Vektor
Candi	[-0.9415, 2.2825, 1.9582, 5.2275, -6.4270]
Borobudur	[-2.3799, 3.5897, 4.6346, 1.5529, -6.1645]
Prambanan	[-1.3920, 0.8588, -0.7879, 1.1634, -4.3542]
Pantai	[0.7602, 4.1665, -2.3070, 0.6921, -0.5014]
Kuta	[-5.6702, -0.1419, -2.2161, 6.1087, -2.8291]
Gunung	[-2.2090, 4.4304, 1.5556, 5.4768, 2.6816]
Merapi	[-0.0657, 3.1969, -1.8285, 1.2381, -2.4020]
Bali	[0.6212, 5.8469, -1.8339, -0.0835, -4.9228]
Yogyakarta	[1.6938, 4.3526, -1.3604, -1.2850, -3.8225]
Indonesia	[0.6782, -1.8261, 2.8702, -2.7945, 0.0223]

3.2.5 Pemodelan Named Entity Recognition

Langkah awal dalam membangun model Named Entity Recognition adalah melakukan *data splitting* terlebih dahulu. *Data splitting* merupakan proses membagi data menjadi dua pembagian yang biasa disebut data uji dan data latih. Sebagian data latih yang nantinya akan dibagi menjadi *data validation*. *Data validation* merupakan data yang digunakan untuk menguji hasil prediksi dalam model saat melakukan proses pengujian dan berguna untuk mencegah terjadinya *overfitting* saat validasi model. *Overfitting* merupakan keadaan ketika model mempelajari dengan sangat teliti di data latih sehingga mendapatkan hasil terlalu baik sehingga mendapatkan akurasi yang sangat tinggi, tetapi jika memproses data baru akan mendapatkan akurasi rendah. Kemudian, untuk data latih yang tidak tercakup dalam *data validation* akan digunakan untuk melatih model. Setelah itu model yang sudah terlatih dari data latih dan validasi yang sudah dilatih dengan data validasi, maka akan dilakukan pengujian model dengan data uji. Pengujian ini bermanfaat untuk mengetahui performa model yang telah dibangun sebelumnya.

Langkah berikutnya merupakan membangun model *Named Entity Recognition*. Penelitian ini model yang akan dibangun merupakan model yang menggunakan metode *Bidirectional Encoder Representations from Transformers* (BERT). Pemodelan dilakukan

dengan cara import *transformer* yang menyediakan package kelas BertForTokenClassification untuk model NER. BertForTokenClassification dengan melakukan fine-tuning model yang mengelilingi BertModel dan menambahkan token-level classifier ke dalam BertModel. Token-level classifier merupakan lapisan yang mengambil input dari *hidden state* terakhir dari urutan. Model ini juga menggunakan Teknik *dropout* agar mencegah terjadinya *overfitting* pada model yang telah dirancang. *Dropout* dapat mencegah terjadinya *overfitting* dan dapat meningkatkan performa model. *Dropout* mengatasi *overfitting* dengan cara menghapus sementara *neuron* yang terpilih acak dari jaringan selama proses pelatihan. Gambar 3.3 menunjukkan teknik *dropout*



Gambar 3.3 Teknik dropout

Dalam penelitian ini akan dilakukan beberapa skenario, Skenario awal pada model BERT akan menggunakan dropout sebesar 0.2 untuk mencegah *overfitting*. Fungsi optimasi yang digunakan dalam penelitian ini adalah *AdamW*. Cacah epoch yang digunakan adalah 4 dan *batch size* sebesar 32 seperti yang dilakukan penelitian (Devlin et al., 2019). Kemudian akan terdapat 3 skenario yang dilakukan pada penelitian ini, pada skenario 1 model BERT akan melakukan perbandingan jumlah dropout yaitu 0.2 dan 0.3. Skenario 2 model BERT akan melakukan perbandingan *batch size* yaitu 32 dan 64. Skenario 3 model BERT akan melakukan perbandingan *epoch* yaitu 4 dan 10. Konfigurasi *hyperparameter* yang memiliki performa terbaik dalam setiap skenario akan digunakan dalam skenario-skenario selanjutnya. Skenario dari model BERT terdapat dalam Tabel 3.12.

Tabel 3.12 Rangkuman scenario model BERT

Skenario	<i>Hypeparameters</i>	Konfigurasi
1	<i>Dropout</i>	0.2
		0.3
2	<i>Epoch</i>	4
		10
3	<i>Batch size</i>	32
		64

3.2.6 Evaluasi Model

Evaluasi model merupakan proses yang digunakan untuk mengetahui seberapa baik kinerja model NER sehingga dapat diukur dengan menggunakan *F1-Score*. Menurut pendapat (Putra & Hidayatullah, 2021) memilih pengukuran dengan *F1-Score* dikarenakan penggunaan *F1-Score* lebih cocok digunakan daripada menggunakan akurasi, karena sebagian besar dalam penerapan entitas NER merupakan label O yang merujuk pada token-token dan bukan merupakan label entitas bernama sehingga berhasil mendapatkan akurasi tinggi (Putra & Hidayatullah, 2021). Hasil *F1-Score* diperoleh dari penghitungan nilai rata-rata harmonik dari *precision* dan *recall*. Dalam perhitungan *F1-Score* dapat dijelaskan bahwa 1 merupakan skor tertinggi dan 0 merupakan skor terendah. *Precision* merupakan banyaknya hasil data positif yang benar dibagi dengan banyaknya seluruh hasil positif sedangkan *Recall* merupakan banyaknya hasil data positif yang benar dibagi dengan banyaknya hasil semua data yang seharusnya bernilai positif. Oleh karena itu, penelitian ini menggunakan *F1-Score*. Perhitungan *F1-Score* terdapat persamaan pada (3.1), karena dalam penerapan NER akan mendapatkan hasil beberapa kelas label, maka dalam mencari *f1-score* dibutuhkan parameter *average* yang meliputi *micro*, *macro*, *weighted*. *Micro* merupakan hasil *f1-score* dengan mempertimbangkan total *true positive*, *false negative*, dan *false positive* secara keseluruhan. *Macro* merupakan hasil *f1-score* dengan menghitung setiap labelnya dan mengembalikan rata-rata dan tidak mempertimbangkan proporsi untuk setiap labelnya dalam *dataset*. *Weighted* akan menghitung *F1-score* untuk setiap label dan mengembalikan rata-rata dengan mempertimbangkan proporsi untuk setiap label dalam *dataset* (Putra & Hidayatullah, 2021).

$$F1-Score = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (3.1)$$

3.2.7 Deteksi Entitas

Dalam tahapan ini, akan melakukan deteksi entitas yang terdapat pada data berupa nama wisata, lokasi wisata, suasana dan fasilitas. Tahapan ini akan menggunakan model dengan nilai F1-Score terbaik yang telah dibuat pada skenario sebelumnya.



BAB IV

HASIL DAN PEMBAHASAN

4.1 Dataset

Data pada penelitian ini digunakan menggunakan data yang telah ada pada penelitian yang sebelumnya. Dataset ini diambil dari *website* TripAdvisor merupakan data *review* tempat wisata. Data yang digunakan dalam penelitian ini berjumlah 7723 *review* tempat wisata. Data *review* tempat wisata ini ditokenisasi menjadi penggalan kata dan menghasilkan 207.994 data yang berupa kata-kata yang kemudian dibagi menjadi dua data yaitu data latih dan data uji.

4.2 Preprocessing

Proses preprocessing ini dilakukan sesudah selesai mengumpulkan data, proses preprocessing ada berbagai macam. Dalam penelitian ini preprocessing yang dilakukan yaitu:

- a. Menghapus karakter yang tidak memiliki arti penting

Langkah pertama dalam melakukan preprocessing yaitu menghapus karakter yang tidak memiliki arti penting. Tahap ini dilakukan untuk menghilangkan karakter yang tidak memiliki arti penting. Gambar 4.1 merupakan implementasi kode program untuk menghapus karakter.

```
def remove_stopword(str): # Berguna untuk menghilangkan kata yang tidak
memiliki arti penting
    stop_words = set(stopwords.words('/content/drive/MyDrive/DATANER/stopwordID.csv'))
    word_tokens = word_tokenize(str)
    filtered_sentence = [w for w in word_tokens if not w in stop_words]
    return ' '.join(filtered_sentence)
```

Gambar 4.1 Kode program untuk menghapus karakter yang tidak memiliki arti penting

- b. Menghapus spasi berlebih

Tahap selanjutnya dalam melakukan preprocessing yaitu menghapus spasi berlebih. Tahap ini dilakukan berguna untuk menghapus spasi berlebih yang berada pada kalimat yang berada pada data. Gambar 4.2 merupakan implementasi kode program untuk menghapus spasi berlebih.

```
def remove_add_space(str): # Berguna untuk menghapus spasi berlebih
    str = re.sub('[\s]+', ' ', str)
    return str;
    return 0;
```

Gambar 4.2 Kode program untuk menghapus karakter berlebih

c. Menghapus Karakter NON ASCII

Tahap selanjutnya dalam melakukan preprocessing yaitu menghapus karakter NON-ASCII. Tahap ini dilakukan berguna untuk menghilangkan karakter karakter yang tidak termasuk dalam kategori kode ASCII. Gambar 4.3 merupakan implementasi kode program untuk menghapus karakter NON-ASCII.

```
def remove_non_ascii(str): # Berguna untuk menghapus code ascii
    return "".join(i for i in str if ord(i)<128)
```

Gambar 4.3 Kode program menghapus karakter NON-ASCII

d. Menghapus Digit

Tahap selanjutnya dalam melakukan preprocessing yaitu menghapus digit. Tahap ini dilakukan berguna untuk menghapus digit karena dalam penelitian ini tidak menggunakan entitas yang berhubungan dengan digit, sehingga dalam preprocessing dilakukan penghapusan digit. Gambar 4.4 merupakan implementasi kode program untuk menghapus digit.

```
def remove_digit(str):
    return re.sub(r'^[a-z ]*([.0-9])*\d', '', str)
```

Gambar 4.4 Kode program menghapus digit.

e. Menghapus URL

Tahap selanjutnya dalam melakukan preprocessing yaitu menghapus URL. Tahap ini dilakukan berguna untuk membersihkan kata-kata yang mengandung URL. Gambar 4.5 merupakan implementasi kode program untuk menghapus URL.

```
def remove_url(str): # Berguna untuk menghapus review dengan website
    str = re.sub(r'(?i)\b((?:https?://|www\d{0,3}[.]|[a-z0-9.\-]+[.][a-z]{2,4})/?(?:[^\s()<>+|\\((?![^\s()<>+|\\([^\s()<>+|\\))*)\\)))+(?:\\((?![^\s()<>+|\\([^\s()<>+|\\))*)\\)|\\([^\s()<>+|\\))*)\\)|[^\s!()\[\]{};:\\".,<?>«»“”‘’]))', '', str)
    return str
```

Gambar 4.5 Kode program untuk menghapus URL.

f. Menghapus *Hastag* dan *Mention*

Tahap selanjutnya dalam melakukan preprocessing yaitu menghapus karakter *hashtag* dan *mention*. Tahap ini dilakukan berguna untuk membersihkan karakter hashtag dan mention.

Karakter twitter yang dihapus yaitu *mention* dan *hashtag*. Gambar 4.6 merupakan implementasi kode program untuk menghapus karakter *mention* dan *hashtag*.

```
def remove_mention_hashtag(str): # Berguna untuk menghapus mention dan hashtag
# # html
# str = re.sub(r'<[^>]+>', ' ', str)
# mention
str = re.sub(r'(?:@[\w_]+)', ' ', str)
# hashtag
str = re.sub(r'(?:\#[\w_]+[\w\'\_\-]*[\w_]+)', ' ', str)
# RT/cc
str = str = re.sub('RT', '', str)
return str
```

Gambar 4.6 Kode program untuk menghapus karakter *mention* dan *hashtag*.

g. Menormalkan kata yang tidak lengkap

Tahap selanjutnya dalam melakukan preprocessing yaitu menormalkan kata yang tidak lengkap. Tahap ini dilakukan berguna untuk menormalkan kata yang tidak lengkap. Gambar 4.7 merupakan implementasi kode program untuk menormalkan kata yang tidak lengkap.

```
def normalize_slang_word(str): # Berguna untuk menormalkan kata yang tidak
lengkap
    text_list = str.split(' ')
    slang_words_raw = pd.read_csv('/content/drive/MyDrive/DATANER/slang_word_list.csv', sep=',',
header=None)
    slang_word_dict = {}

    for item in slang_words_raw.values:
        slang_word_dict[item[0]] = item[1]

    for index in range(len(text_list)):
        if text_list[index] in slang_word_dict.keys():
            text_list[index] = slang_word_dict[text_list[index]]

    return ' '.join(text_list)
```

Gambar 4.7 Kode program untuk mernormalkan kata yang tidak lengkap.

h. Menggabungkan semua *preprocessing*

Tahap selanjutnya dalam melakukan *preprocessing* yaitu menggabungkan semua kode diatas dan selanjutnya dijadikan sebuah fungsi, sehingga semua kode diatas menjadi satu dalam melakukan *preprocessing*. Gambar 4.8 merupakan implementasi kode program untuk menggabungkan semua kode *preprocessing* yang akan dilakukan.

```
def preprocessing(str):
    str = remove_url(str)
    str = remove_mention_hastag(str)
    str = remove_digit(str)
    str = remove_non_ascii(str)
    str = normalize_slang_word(str)
    str = remove_stopword(str)
    str = remove_add_space(str)

    return str
```

Gambar 4.8 Kode program menggabungkan semua kode *preprocessing*.

i. Tokenisasi

Tokenisasi merupakan proses pemecahan data yang berupa kumpulan kalimat-kalimat akan dipecah menjadi kata-kata yang kemudian disimpan dalam file berektensi .csv beserta nomor kalimatnya yang menandakan urutan kalimat tersebut. Gambar 4.9 merupakan implementasi kode program dalam melakukan proses tokenisasi. Tahap ini menghasilkan sebanyak 207.994 token kata. Gambar 4.10 merupakan hasil dari proses tokenisasi.

```
ct = CRFTagger()
ct.set_model_file('all_indo_man_tag_corpus_model.crf.tagger')

def tagging(sent):
    xx = word_tokenize(sent)
    hasil = ct.tag_sents([xx])
    return hasil
```

Gambar 4.9 Kode program proses tokenisasi

Sentence 1	Main
	kesini
	salah
	warisan
	budaya
	indonesia
	candi
	salahsatu
	terbesar
	diindonesia
	tinggal
	yogya
	jarak
	kesini
	lumayan
	sihh
	sayang
	diy
	gapernah
	candi
	Pengalaman
	berharga

Gambar 4.10 Hasil tokenisasi

4.3 Pelabelan Entitas

Pelabelan Entitas ini dilakukan setelah selesai melakukan proses *preprocessing* yang sudah ditokenisasi sehingga menjadi pecahan kata-kata. Pelabelan entitas merupakan proses pelabelan pada data dengan memberi label sesuai kategori masing-masing. Label yang akan diberikan pada tiap kata 9, yaitu B-WISATA, I-WISATA, B-LOCATION, I-LOCATION, B-FASILITAS, I-FASILITAS, B-SUASANA, I-SUASANA dan O. Gambar 4.11 menunjukkan data yang sudah diberi label sesuai kategorinya. Dalam kolom pertama menunjukkan nomor urutan ulasan, kolom kedua menunjukkan kata-kata yang sudah ditoken pada ulasan dan kolom ketiga menunjukkan label yang diberikan pada setiap kata yang sudah ditoken.

Sentence 3	Saya	O	Sentence 4	jawa	B-LOKASI
	mengunjungi	O		tengah	I-LOKASI
	Borobudur	B-WISATA		wisata	O
	SD	O		bagus	O
	Baru	O		spot	B-FASILITAS
	kesempatan	O		foto	I-FASILITAS
	mengunjungi	O		alam	O
	Borobudur	B-WISATA		candi	B-WISATA
	Kami	O		borobudur	I-WISATA
	mengunjungi	O		gambaran	O
	Candi	B-WISATA		sejarah	O
	Borobudur	I-WISATA		candi	B-WISATA
	sore	O	Sentence 5	Menikmati	O
	Desember	O		perjalanan	O
	Pengunjung	O		tur	O
	Candi	B-WISATA		Jogja	B-LOKASI
	Borobudur	I-WISATA		mengunjungi	O
	padat	O		Candi	B-WISATA
	Banyak	O		Borobudur	I-WISATA
	rombongan	O		Candi	B-WISATA

Gambar 4.11 Menunjukkan kata yang sudah diberi label

Tabel 4.1 Jumlah token pada setiap label

Label	Jumlah Token
B-WISATA	13547
I-WISATA	5961
B-LOKASI	3672
I-LOKASI	269
B-FASILITAS	1553
I-FASILITAS	357
B-SUASANA	1399
I-SUASANA	183
O	181053

4.4 Mempersiapkan Data Masukan

Dalam membangun model *Named Entity Recognition*, perlu dilakukan mempersiapkan data masukan terlebih dahulu. Proses dalam mempersiapkan data masukan pada model BERT. Berikut ini merupakan penjelasan prosesnya:

Data Masukan pada Model BERT. Kemudian data tersebut akan dipersiapkan dengan dibentuk menjadi sebuah *list* yang menjadi sebuah sampel menggunakan kelas *SentenceGetter*. Kelas *SentenceGetter* bertujuan untuk memisahkan antara setiap kalimat dari kalimat lainnya, sama seperti langkah sebelumnya. Gambar 4.12 menunjukkan kode program dalam tahapan ini.

```
class SentenceGetter(object):
    def __init__(self, data):
        self.n_sent = 1
        self.data = data
        self.empty = False
        agg_func = lambda s: [(w, p, t) for w, p, t in
zip(s["Word"].values.tolist(),
s["POS"].values.tolist(),
s["Tag"].values.tolist())]
        self.grouped = self.data.groupby("Sentence #").apply(agg_func)
        self.sentences = [s for s in self.grouped]

    def get_next(self):
        try:
            s = self.grouped["Sentence: {}".format(self.n_sent)]
            self.n_sent += 1
            return s
        except:
            return None
```

Gambar 4.12 Kode program persiapan data ke model BERT

4.5 Ekstraksi Fitur

Proses ekstraksi fitur ini dilakukan setelah mempersiapkan data ke model BERT, Ekstraksi fitur yang digunakan dalam penelitian ini merupakan teknik *WordPiece embeddings*. *WordPiece embedding* ini bertujuan untuk mempelajari berbagai kata dalam jumlah besar dan secara otomatis. Proses ekstraksi fitur pada BERT, setiap kata yang di token dengan *WordPiece* akan mendapatkan tambahan awalan ([CLS]). Pasangan kalimat dikemas bersama menjadi satu urutan, kalimat dibedakan dengan token khusus ([SEP]) pada akhir kalimat. Token yang diberikan representasi inputnya dibangun dengan menjumlahkan token, segmen, dan posisi embeddings. Input ini digunakan dalam BERT pre-trained untuk tugas MLM (Masked

Language Modelling) dan NSP (Next Sentence Prediction). Dibawah ini menunjukkan kode program ekstraksi fitur pada Gambar 4.13 dengan teknik *WordPiece embeddings*.

```
tokenizer = BertTokenizer.from_pretrained('cahya/bert-base-indonesian-522M', do_lower_case=False)
def tokenize_and_preserve_labels(sentence, text_labels):
    tokenized_sentence = []
    labels = []

    for word, label in zip(sentence, text_labels):

        # Tokenisasi kata dan hitung # subkata yang dipecah menjadi kata
        tokenized_word = tokenizer.tokenize(word)
        n_subwords = len(tokenized_word)

        # Tambahkan kata tokenized ke daftar kata terakhir tokenized
        tokenized_sentence.extend(tokenized_word)

        # Tambahkan label yang sama ke daftar label baru `n_subwords`
        labels.extend([label] * n_subwords)

    return tokenized_sentence, labels
tokenized_texts_and_labels = [
    tokenize_and_preserve_labels(sent, labs)
    for sent, labs in zip(sentences, labels)
]
input_ids = pad_sequences([tokenizer.convert_tokens_to_ids(txt) for txt in
tokenized_texts],
                        maxlen=MAX_LEN, dtype="long", value=0.0,
                        truncating="post", padding="post")
tags = pad_sequences([[tag2idx.get(l) for l in lab] for lab in labels],
                    maxlen=MAX_LEN, value=tag2idx["PAD"], padding="post",
                    dtype="long", truncating="post")
attention_masks = [[float(i != 0.0) for i in ii] for ii in input_ids]
```

Gambar 4.13 Ekstraksi fitur dengan teknik *WordPiece embedding*

4.6 Pemodelan Named Entity Recognition

Dalam melakukan pemodelan Named Entity Recognition ada beberapa tahap yang dilakukan. Berikut ini merupakan tahapan yang dilakukan dalam pemodelan NER yaitu :

a. *Splitting Data*

Data splitting merupakan data yang digunakan untuk membangun sebuah model. Data splitting ada dua bagian, yaitu data latih dan data uji. Pembagian data menggunakan *library* Sckit-Learn dengan nama kelas *train_test_split*. Dengan kelas ini, data dapat dibagi menjadi data latih dan data uji secara acak dalam proporsi. Dalam kasus ini data latih dan data uji dibagi sebanyak 0.2, yang berarti data latih sebanyak 80% dan data uji sebanyak 20%. Gambar 4.14 menunjukkan kode program data splitting pada model BERT.

```

from sklearn.model_selection import train_test_split
tr_inputs, val_inputs, tr_tags, val_tags = train_test_split(input_ids, tags,
random_state=2018, test_size=0.2)

```

Gambar 4.14 Kode program data splitting

b. Membangun Model BERT

Membangun model BERT dilakukan dengan menggunakan *library* dari *transformers* dengan nama kelas *BertForTokenClassification*. Kelas ini digunakan khusus untuk melakukan untuk membangun model NER dan menerapkan *fine-tuning* model yang mengelilingi BertModel dan menambahkan *token-level classifier*. *Token-level classifier* merupakan suatu lapisan yang mengambil input dari *hidden state* urutan terakhir. Selanjutnya, tahap berikutnya untuk membangun model BERT adalah load *bert_base_case* model yang sudah di *pre-train* didalam *library transformers*. Fungsi optimasi yang digunakan pada model ini adalah fungsi *AdamW*. Gambar 4.15 menunjukkan kode program membangun model BERT dan Gambar 4.16 menunjukkan kode program *fine-tuning*.

```

import transformers
from transformers import BertForTokenClassification, AdamW, TFBertModel

model = BertForTokenClassification.from_pretrained(
    'cahya/bert-base-indonesian-522M',
    num_labels = len(tag2idx),
    output_attentions = False,
    output_hidden_states = False,
    attention_probs_dropout_prob = 0.2,
    hidden_dropout_prob = 0.2
)

model.cuda();

```

Gambar 4.15 Kode program membangun model BERT

```

#FULL_FINETUNING = True
if FULL_FINETUNING:
    param_optimizer = list(model.named_parameters())
    no_decay = ['bias', 'gamma', 'beta']
    optimizer_grouped_parameters = [
        {'params': [p for n, p in param_optimizer if not any(nd in n for nd
in no_decay)]},
        {'weight_decay_rate': 0.01},
        {'params': [p for n, p in param_optimizer if any(nd in n for nd in
no_decay)]},
        {'weight_decay_rate': 0.0}
    ]
else:
    param_optimizer = list(model.classifier.named_parameters())

```

```

optimizer_grouped_parameters = [{"params": [p for n, p in
param_optimizer]]}

optimizer = AdamW(
    optimizer_grouped_parameters,
    lr=3e-5,
    eps=1e-8
)

```

Gambar 4.16 Kode program proses *fine-tuning*

c. Melatih Model

Dalam melatih model BERT, ada beberapa fungsi yang digunakan. Pertama membuat model dalam *mode training* dengan menggunakan *model.train()*. Selanjutnya menambahkan *batch* ke GPU supaya dapat meningkatkan kinerja model dengan menggunakan *batch = tuple(t.to(device) for t in batch)*. Kemudian sebelum melaksanakan *backward pass* model akan menghapus semua gradien yang sudah dihitung sebelumnya dengan fungsi *model.zero_grad()*. Setelah sudah menghapus perhitungan gradien sebelumnya, langkah selanjutnya merupakan *forward pass* untuk mendapat nilai *loss*. Langkah selanjutnya untuk mendapatkan nilai *loss* menggunakan fungsi *loss = outputs[]*. Setelah mendapatkan nilai *loss*, langkah selanjutnya yaitu melakukan *backward pass* untuk menghitung gradien. Kemudian untuk mencegah masalah ‘*exploding gradient*’ dalam model digunakan fungsi *torch.nn.utils.clip_grad_norm_(parameters=model.parameters(), max_norm=max_grad_norm)*. Kemudian akan digunakan fungsi *optimizer.step()* yang bertujuan untuk melakukan pengulangan ke semua parameters dan melakukan update pada semua parameters. Selanjutnya dilakukan *update* pada *learning rate* untuk menyesuaikan berdasarkan beberapa *epochs*. Gambar 4.17 menunjukkan kode program untuk tahap melatih model BERT.

```

from segeval.metrics import f1_score, accuracy_score
## Menyimpan loss value dan validasi loss value
loss_values, validation_loss_values = [], []

for _ in trange(epochs, desc="Epoch"):

    # Masukkan model ke mode pelatihan.
    model.train()
    # Reset the total loss for this epoch.
    total_loss = 0

    # Training loop
    for step, batch in enumerate(train_dataloader):
        # menambahkan batch ke gpu
        batch = tuple(t.to(device) for t in batch)

```

```

        b_input_ids, b_input_mask, b_labels = batch
        # Selalu bersihkan gradien yang dihitung sebelumnya sebelum melakukan
        passing mundur.
        model.zero_grad()
        # forward pass
        # This will return the loss (rather than the model output)
        # because we have provided the `labels`.
        outputs = model(b_input_ids, token_type_ids=None,
                        attention_mask=b_input_mask, labels=b_labels)

        # get the loss
        loss = outputs[0]
        # Perform a backward pass to calculate the gradients.
        loss.backward()
        # track train loss
        total_loss += loss.item()
        # Clip the norm of the gradient
        # This is to help prevent the "exploding gradients" problem.
        torch.nn.utils.clip_grad_norm_(parameters=model.parameters(),
max_norm=max_grad_norm)
        # update parameters
        optimizer.step()
        # Update the learning rate.
        scheduler.step()

        # Calculate the average loss over the training data.
        avg_train_loss = total_loss / len(train_dataloader)
        print("Average train loss: {}".format(avg_train_loss))

        # Store the loss value for plotting the learning curve.
        loss_values.append(avg_train_loss)

```

Gambar 4.17 Kode Program Melatih BERT

4.7 Evaluasi Model

Tahap evaluasi model ini dilakukan untuk mengukur kinerja dari model BERT yang sudah dibangun. Performa model dari setiap scenario yang sudah dibangun akan dilakukan perbandingan menggunakan rata-rata F1-Score yang telah diperoleh, hal ini bertujuan untuk mendapat model terbaik dalam melakukan pemodelan *Named Entity Recognition* dengan menggunakan model BERT. Gambar 4.18 menunjukkan kode program untuk tahap evaluasi BERT. Gambar 4.16

```

model.eval()
# Reset the validation loss for this epoch.
eval_loss, eval_accuracy = 0, 0
nb_eval_steps, nb_eval_examples = 0, 0
predictions, true_labels = [], []
for batch in valid_dataloader:
    batch = tuple(t.to(device) for t in batch)
    b_input_ids, b_input_mask, b_labels = batch

    # Memberitahu model untuk tidak menghitung atau menyimpan gradien,
    # menghemat memori dan mempercepat validasi
    with torch.no_grad():

```

```

# Teruskan pass, hitung prediksi logit.
# Ini akan mengembalikan log daripada kehilangan karena kami
belum memberikan label.
outputs = model(b_input_ids, token_type_ids=None,
                 attention_mask=b_input_mask, labels=b_labels)
# Pindahkan log dan label ke CPU
logits = outputs[1].detach().cpu().numpy()
label_ids = b_labels.to('cpu').numpy()

# Hitung akurasi untuk kumpulan kalimat uji ini.
eval_loss += outputs[0].mean().item()
predictions.extend([list(p) for p in np.argmax(logits, axis=2)])
true_labels.extend(label_ids)

eval_loss = eval_loss / len(valid_dataloader)
validation_loss_values.append(eval_loss)
print("Validation loss: {}".format(eval_loss))
pred_tags = [tag_values[p_i] for p, l in zip(predictions, true_labels)
              for p_i, l_i in zip(p, l) if
tag_values[l_i] != "PAD"]
valid_tags = [tag_values[l_i] for l in true_labels
               for l_i in l if tag_values[l_i] != "PAD"]
print("Validation Accuracy: {}".format(accuracy_score(pred_tags,
valid_tags)))
print("Validation F1-Score: {}".format(f1_score(pred_tags,
valid_tags)))
print()

```

Gambar 4.18 Kode Program Evaluasi BERT

a. Skenario 1

Dalam skenario pertama model BERT, dilakukan perbandingan jumlah dropout yang diterapkan. Hasil evaluasi dapat dilihat pada Tabel 4.2. Dapat diketahui pada hasil evaluasi dari kedua dropout yang diuji, jumlah *dropout* yang diterapkan dan mendapatkan hasil *F1-Score* yang terbaik yaitu *dropout* dengan jumlah 0.2. *Dropout* yang 0.2 lebih baik hasilnya dari pada *dropout* 0.3. Dalam penggunaan *dropout* 0.2 mendapatkan *F1-Score* rata-rata 74% sedangkan penggunaan *dropout* 0.3 mendapatkan *F1-Score* rata-rata 73%. Oleh karena itu, pada skenario berikutnya akan menggunakan *dropout* sebesar 0.2.

Tabel 4.2 Hasil evaluasi skenario 1 model BERT

Skenario	Dropout	F1- Score WISATA	F1- Score LOKASI	F1- Score FASILITAS	F1- Score SUASANA	F1-Score rata- rata
1	0.2	80%	74%	55%	51%	74%
	0.3	78%	71%	54%	51%	72 %

b. Skenario 2

Dalam skenario kedua model BERT, dilakukan perbandingan jumlah *epoch*. Hasil evaluasi dapat dilihat pada Tabel 4.3. Dapat diketahui pada hasil evaluasi, dari kedua *epoch* yang diuji, jumlah epoch yang memiliki hasil F1-Score terbaik yaitu jumlah *epoch* 4. Jumlah *epoch* 4 mendapatkan F1-Score 74% sedangkan jumlah *epoch* 10 mendapatkan F1-Score 73.8%. Penggunaan jumlah *epoch* 4 dan jumlah *epoch* 10 ini dikarenakan dalam penelitian (Devlin et al., 2019) juga menggunakan jumlah *epoch* tersebut untuk perbandingan hasil F1-Score. Oleh karena itu, pada skenario berikut akan menggunakan jumlah *epoch* sebanyak 4.

Tabel 4.3 Hasil evaluasi skenario 2 model BERT

Skenario	Epoch	F1- Score WISATA	F1- Score LOKASI	F1- Score FASILITAS	F1- Score SUASANA	F1-Score rata -rata
2	4	80%	74%	55%	51%	74%
	10	79%	72%	54%	49%	73%

c. Skenario 3

Dalam skenario ketiga model BERT, dilakukan perbandingan jumlah *batch size*. Hasil evaluasi dapat dilihat pada Tabel 4.4. Dapat diketahui bahwa, model evaluasi dengan *batch size* 32 mendapatkan hasil yang lebih baik dari pada *batch size* 64. Dalam penerapan evaluasi dalam *batch size* 32 mendapatkan hasil F1-Score rata-rata 74% sedangkan untuk *batch size* 64 mendapatkan hasil F1-Score rata-rata 48%. Oleh karena itu, pada skenario berikutnya akan menggunakan *batch size* sebesar 32.

Tabel 4.4 Hasil evaluasi skenario 3 model BERT

Skenario	Batch size	F1- Score WISATA	F1- Score LOKASI	F1- Score FASILITAS	F1- Score SUASANA	F1-Score Rata-rata
3	32	80%	74%	55%	51%	74%
	64	51%	49%	19%	27%	48%

4.8 Deteksi Entitas

Berdasarkan perbandingan pada skenario pada model BERT yang telah dilakukan sebelumnya, model BERT yang menghasilkan kinerja terbaik menggunakan *dropout* sebesar 0.2, *batch size* sebesar 32 dan jumlah *epoch* 4. Dari model yang memiliki kinerja terbaik akan diimplementasikan untuk melakukan deteksi entitas pada *review* tempat wisata. Entitas yang akan dideteksi terdiri dari beberapa kategori, yaitu nama tempat wisata, nama lokasi wisata, fasilitas, dan suasana, sedangkan untuk kata-kata yang tidak termasuk dalam kategori tersebut akan masuk kedalam kategori *outside*. Hasil dari deteksi entitas menggunakan metode BERT yang memiliki hasil terbaik ditunjukkan pada Gambar 4.19.

0	[CLS]	B-FASILITAS	kamar	0	.
0	aku	I-FASILITAS	mandi	0	suasana
0	pergi	0	dan	0	di
0	ke	B-FASILITAS	shuttle	B-WISATA	pantai
B-LOKASI	yogyakarta	I-FASILITAS	bus	I-WISATA	pandawa
0	untuk	0	.	0	sangat
0	melihat	0	kayak	B-SUASANA	sejuk
B-WISATA	pantai	0	,	0	dan
I-WISATA	pandawa	0	kano	B-SUASANA	nyaman
0	yang	0	,	0	sehingga
0	terletak	B-WISATA	kali	0	betah
0	di	0	kuning	0	untuk
B-LOKASI	sleman	0	.	0	berwisata
0	,	0	pandawa	0	di
0	fasilitasnya	0	dan	B-WISATA	pantai
0	ada	B-LOKASI	bali	I-WISATA	pandawa
B-FASILITAS	mushola	0	selatan	0	.
0	,			0	[SEP]

Gambar 4.20 Hasil proses deteksi entitas menggunakan model BERT

Dari **Error! Reference source not found.**, dapat terlihat bahwa dalam mendeteksi tidak selalu benar dikarenakan hanya mendapatkan F1-Score 74%. Ditunjukkan pada **Error! Reference source not found.** bahwa kata “kuning” yang seharusnya masuk dalam kategori entitas I-WISATA tidak terdeteksi, namun justru masuk dalam kategori *Outside* dan kata “selatan” yang seharusnya masuk dalam kategori entitas I-LOKASI tidak terdeteksi, namun justru masuk dalam kategori *Outside*. Hal ini disebabkan karena performa model BERT masih perlu ditingkatkan lagi ketika melakukan proses pembelajaran.

Error! Reference source not found. merupakan hasil yang telah didapatkan dari deteksi entitas dengan menggunakan model BERT, diharapkan penelitian ini dapat diambil manfaatnya. Sehingga hasil dari penelitian ini bermanfaat untuk pengembangan sistem pada *website* maupun aplikasi yang berhubungan dengan *domain* wisata agar mempermudah dalam menemukan

informasi penting yang dibutuhkan calon wisatawan apalagi jika kategori entitas dalam pengembangan model NER semakin banyak pasti lebih mempermudah calon wisatawan untuk menemukan informasi lebih cepat. Terutama untuk calon wisatawan dari luar negeri, mungkin dengan adanya perkembangan penelitian tentang NER dalam domain wisata akan sangat membantu ketika calon wisatawan akan berkunjung di tempat wisata yang berada di Indonesia.



BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan penelitian *named entity recognition* pada *review* tempat wisata menggunakan metode *Bidirectional Encoder Representations from Transformers*, dapat disimpulkan bahwa:

- a. Penerapan *Named Entity Recognition* dapat membantu dalam mengidentifikasi informasi penting pada *review* tempat wisata. Terdapat beberapa tahap yang dilakukan yaitu pengumpulan *dataset*, *preprocessing*, pelabelan entitas, ekstraksi fitur, pemodean NER, evaluasi model dan deteksi entitas. NER dapat mengenali kategori entitas yang ada dalam *review* wisata seperti nama tempat wisata, nama lokasi wisata, fasilitas, dan suasana. Model NER dirancang dengan metode BERT yang dapat melatih representasi dua arah dari teks yang tidak berlabel dengan bersama-sama mengkondisikan konteks dari kiri dan kanan di semua lapisan, sehingga dalam mengenali entitas akan lebih mudah. Sebelum membuat model model BERT akan melakukan *pre-training* bertujuan untuk model BERT memahami dan mempelajari pada data tidak berlabel dengan dua tugas *unsupervised* yaitu *Masked Language Model* (MLM) dan *Next Sentence Prediction* (NSP). Oleh karena itu model BERT dapat mempelajari informasi dengan mengkondisikan konteks pada label sehingga dalam memprediksi akan memperhatikan konteks dari label sebelumnya dan setelahnya.
- b. Penelitian ini menghasilkan model yang dapat menerapkan *named entity recognition* dan dapat memprediksi entitas dengan hasil yang cukup baik. Dalam penelitian NER dengan metode BERT yang telah diterapkan, diketahui *hyperparameter* terbaik dalam membangun model NER dengan metode BERT yaitu menggunakan *dropout* sebesar 0.2, *batch size* sebesar 32 dan jumlah *epoch* 4. Dari keseluruhan skenario yang sudah dilakukan untuk penerapan NER dengan metode BERT mendapatkan F1-Score terbaik yaitu sebesar 75%. Membangun model NER menggunakan BertForTokenClassification dengan *load* model “cahya/bert-base-indonesian-522M”. Dalam membangun model *ngeload* “cahya/bert-base-indonesian-522M” dikarenakan *dataset* yang digunakan dalam penelitian ini adalah berbahasa Indonesia.

5.2 Saran

Berdasarkan penelitian ini, peneliti berharap agar penelitian ini dapat dikembangkan lagi dengan beberapa saran berikut:

- a. Menambah kategori entitas yang akan dikenali pada *dataset* seperti jam operasional, dan biaya wisata.
- b. Menggunakan data berbahasa selain bahasa Indonesia.
- c. Mengambil sumber data dari *instagram* atau *twitter* dan memilih wisata populer yang berada di didunia.
- d. Menambah jumlah *dataset*, sehingga entitas yang jumlah nya masih sedikit seperti dalam penelitian ini yaitu entitas suasana dapat lebih dikenali dengan baik.



DAFTAR PUSTAKA

- Abida, R. (2019). *TEMPAT WISATA MENGGUNAKAN METODE CONVOLUTIONAL NEURAL NETWORK (CNN)*.
- Ahmad Hania, A. (2017). Mengenal Artificial Intelligence, Machine Learning, & Deep Learning. *Jurnal Teknologi Indonesia*, (June). Retrieved from <https://amt-it.com/mengenal-perbedaan-artificial-intelligence-machine-learning-deep-learning/>
- Cambria, E., Valdivia, A., Luzón, M. V., & Herrera, F. (2017). *AFFECTIVE COMPUTING AND SENTIMENT ANALYSIS Sentiment Analysis in TripAdvisor*. Retrieved from www.computer.org/intelligent
- Chantrapornchai, C., & Tunsakul, A. (2019). Information Extraction based on Named Entity for Tourism Corpus. *JCSSE 2019 - 16th International Joint Conference on Computer Science and Software Engineering: Knowledge Evolution Towards Singularity of Man-Machine Intelligence*, 187–192. <https://doi.org/10.1109/JCSSE.2019.8864166>
- Chantrapornchai, C., & Tunsakul, A. (2021). Information extraction on tourism domain using SpaCy and BERT. *ECTI Transactions on Computer and Information Technology*, 15(1), 108–122. <https://doi.org/10.37936/ecti-cit.2021151.228621>
- Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *NAACL HLT 2019 - 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies - Proceedings of the Conference*, 1(Mlm), 4171–4186.
- Fimoza, D. (2019). Analisis Sentimen Terhadap Film Indoensia Dengan Pendekatan BERT. *Expert Systems with Applications*, 118, 272–299. Retrieved from <http://repositori.usu.ac.id/handle/123456789/30445%0Ahttps://linkinghub.elsevier.com/retrieve/pii/S0957417418306456>
- Giarsyani, N. (2020). Komparasi Algoritma Machine Learning dan Deep Learning untuk Named Entity Recognition : Studi Kasus Data Kebencanaan. *Indonesian Journal of Applied Informatics*, 4(2), 138. <https://doi.org/10.20961/ijai.v4i2.41317>
- Gravano, A. (2010). Turn-taking and affirmative cue words in task-oriented dialogue. *Dissertation Abstracts International, B: Sciences and Engineering*, 70(8), 4943. <https://doi.org/10.1162/COLI>
- Hu, Y., Nuo, M., & Tang, C. (2019). A Deep Learning Approach for Chinese Tourism Field

- Attribute Extraction. *Proceedings - 2019 15th International Conference on Computational Intelligence and Security, CIS 2019*, 108–112. <https://doi.org/10.1109/CIS.2019.00031>
- Li, J., Sun, A., Han, J., & Li, C. (2020). A Survey on Deep Learning for Named Entity Recognition. *IEEE Transactions on Knowledge and Data Engineering*, XX(XX), 1–1. <https://doi.org/10.1109/tkde.2020.2981314>
- Liang, X., Cao, H., & Zhang, W. (2020). Knowledge Extraction Experiment Based on Tourism Knowledge Graph Q A Data Set. *Proceedings of 2020 IEEE International Conference on Power, Intelligent Computing and Systems, ICPICS 2020*, 828–832. <https://doi.org/10.1109/ICPICS50287.2020.9202197>
- Mansouri, A., Affendey, L. S., & Mamat, A. (2008). Named Entity Recognition Approaches. *Journal of Computer Science*, 8(2), 339–344.
- Putra, M. F. D. A., & Hidayatullah, A. F. (2021). *NAMED ENTITY RECOGNITION PADA ULASAN WISATA MENGGUNAKAN BIDIRECTIONAL LONG SHORT-TERM MEMORY NAMED ENTITY RECOGNITION PADA ULASAN WISATA MENGGUNAKAN BIDIRECTIONAL LONG SHORT-TERM MEMORY*.
- Quijano, A. J., Nguyen, S., & Ordonez, J. (2021). *Bert, albert*,.
- Sabon, V. L., Perdana, M. T. P., Koropit, P. C. S., & Pierre, W. C. D. (2018). Strategi Peningkatan Kinerja Sektor Pariwisata Indonesia Pada ASEAN Economic Community. *Esensi: Jurnal Bisnis Dan Manajemen*, 8(2), 163–176. <https://doi.org/10.15408/ess.v8i2.5928>
- Saputro, K. E., Kusumawardani, S. S., & Fauziati, S. (2017). Development of semi-supervised named entity recognition to discover new tourism places. *Proceedings - 2016 2nd International Conference on Science and Technology-Computer, ICST 2016*, 124–128. <https://doi.org/10.1109/ICSTC.2016.7877360>
- Taher, E., Hoseini, S. A., & Shamsfard, M. (2020). Beheshti-NER: Persian named entity recognition Using BERT. *ArXiv*.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems, 2017-Decem(Nips)*, 5999–6009.
- Wang, Z., Huang, Z., & Gao, J. (2020). Chinese Text Classification Method Based on BERT Word Embedding. *ACM International Conference Proceeding Series*, 66–71. <https://doi.org/10.1145/3395260.3395273>

Xue, L., Cao, H., Ye, F., & Qin, Y. (2019). A method of chinese tourism named entity recognition based on bbhc model. *Proceedings - 2019 IEEE SmartWorld, Ubiquitous Intelligence and Computing, Advanced and Trusted Computing, Scalable Computing and Communications, Internet of People and Smart City Innovation, SmartWorld/UIC/ATC/SCALCOM/IOP/SCI 2019*, (September 1995), 1722–1727. <https://doi.org/10.1109/SmartWorld-UIC-ATC-SCALCOM-IOP-SCI.2019.00307>



LAMPIRAN

